

PersonaLab · VectorAct

AI 서버 설계서

AI Server Design Specification

AI 실시간 연기 코칭 웹서비스 — AI 서버 설계 영역 1~6 통합본 · 개발 기준선

요구사항분석서·기능명세서 v1.4, UI/UX 흐름 및 IA 명세서 v1.4, API 명세서·DB 설계서 최종본, 서버 간 메시지 형식
확정본 v1.0 기준

문서 이력

버전	작성일	작성자	변경 내용
v0.1	2026. 09. 29	24071057 이시규	최초 작성: 설계 영역 1(분석 모델 파이프라인), 설계 영역 6(벡터 DB 활용 목적 및 스키마) 확정 사항 정리
v0.2	2026. 09. 29	24071057 이시규	LLM(Gemma 4 31B, 로컬)·임베딩 모델(KURE-v1) 확정, 서버 하드웨어 및 GPU 배치 추가, 공통 분석 엔진 구조(2.4) 추가, 벡터 차원 확정(1024), 미결정·팀 확인 목록 갱신
v0.3	2026. 09. 29	24071057 이시규	시스템 구성(1.2) 추가: 애플리케이션 서버와 AI 서버·DB 분리. AI 서버 DB 설계(6 장)에 situation_profiles·삭제 동기화 추가. 실시간 코칭 프로토콜(7 장)을 애플리케이션 API 명세서에서 이관(SESSION_STATUS 삭제). 취약점 세부 항목 코드(3.3) 추가. 애플리케이션 문서 수정 현황(8.3) 정리
v0.4	2026. 09. 29	24071057 이시규	팀 확인 답변 반영: 말투 정의, POST_ONLY 유지, FR-LIVE-06 문구, 모델·데이터 이용 조건, 외부 API 전환 조건. 연결 티켓 JWT 화 및 검증 절차(7.1~7.2) 추가. OCR 기능 유지 확정. 팀 확인 목록(8.2) 갱신
v0.5	2026. 09. 29	24071057 이시규	coaching_phrases 스키마 정본을 DB 설계서 11 장(AI 서버 DB)으로 이관, 취약점 화면 상황 적합성 표시 확정, D07 개선 정도 추가 결정 반영. 팀 확인 목록 갱신

버전	작성일	작성자	변경 내용
v0.6	2026. 09. 29	24071057 이시규	D07 개선 정도 계산 방식(최근 30 일 대 직전 30 일) 반영, AI 서버 운영 환경(대학교 AI 서버, 포트 개방 테스트) 기재, 기대 감정 프로파일 저장·삭제 방식(애플리케이션 서버 삭제 통보) 확정, 의성어 처리 방식(M7-M9) 확정
v0.7	2026. 09. 29	24071057 이시규	영역 5 설계: 서버 간 인터페이스(8 장) 신설. Redis Streams 메시지 큐, 메시지 형식·목록, 분석 상태 전이, 신뢰성 규칙, D07 문구 API, 원본 영상 전달, 기간 피드백 생성, 서버 간 인증
v0.8	2026. 09. 29	24071057 이시규	영역 2 설계: 실시간 처리 구조(9 장) 신설. 게이트웨이·워커 분리, 입력 처리 흐름, 과부하 처리, 지연 목표, 모드 전환(복귀 허용), 준실시간 10 초 구간, 분석 전용 모드, 사후 분석 5fps, 재연결, 실측 계획
v0.9	2026. 09. 29	24071057 이시규	영역 3 설계: 점수 산출 로직(10 장) 신설. 항목 역할 분리, 공통 변환 함수, 항목별 세부 지표·초기 기준값, 신뢰도, 분석 불가 판정, 종합 점수, 구간 피드백 기준, 보정·버전 관리. 관련 모듈 임계값(M2-M3-M9-M10, 4.2) 확정
v1.0	2026. 09. 29	24071057 이시규	영역 4 설계: 실시간 코칭 트리거 로직(11 장) 신설. 판단 흐름, 문제 유형(issue_code) 목록·감지 조건, 코칭 강도별 기준, 노출 시점·우선순위, 극적 침묵 판단, 문구 선택, 모드별 동작, 초기값 보정. 6 개 영역 설계 완료
v1.1	2026. 09. 29	24071057 이시규	팀 검증셋(4.6) 절 신설 및 참조 정정(M3, 9.10, 10.8, 11.9), 표지 부제·기준 문서 버전 갱신
v1.2	2026. 10. 03	24071057 이시규	개발 기준선 판. 서버 배치 확정(애플리케이션 서버·Nginx·PostgreSQL·Redis 교내 PC, AI 서버 km-ai 포트 8804, 원본 영상 AWS S3, 외부 공개 없음)과 배치·보안·운영·변경 관리(1.5~1.7) 신설. GPU 1 장 배치(2.5), LLM 을 Gemma 4 소형 모델로 변경(5.3), AI 서버 DB 를 애플리케이션 서버 PC 의 별도 데이터베이스로 변경(6.1), Redis 내부망 접속(8.1-8.9), 실시간 처리 구조 개선안(9.1-9.2, 10/7 재측정 후 확정), 1 차 실측 결과(9.10), VAD 초기값(M5), 코칭 기본 문구 최종본 반영(11.3-11.7), 미결정 사항을 설정값 목록으로 정리(12 장)

목차

1. 설계 기준
2. 분석 파이프라인 구성
3. 분석 모듈 상세
4. 감정 라벨 및 각성도 정의
5. LLM 활용 설계
6. AI 서버 DB 설계
7. 실시간 코칭 프로토콜
8. AI 서버 ↔ 애플리케이션 서버 인터페이스
9. 실시간 처리 구조
10. 점수 산출 로직
11. 실시간 코칭 트리거 로직
12. 설정값 목록과 남은 확인 사항
13. 부록: 설계 결정 이력

1. 설계 기준

1.1 문서 목적 및 범위

본 문서는 PersonaLab VectorAct AI 서버의 분석 구조를 정의함. AI 서버 설계는 6 개 영역으로 구분하여 진행하였으며, 본 판(v1.2)은 6 개 영역의 확정 내용과 2026. 10. 02 서버 배치 결정을 반영한 **개발 기준선**임. 이후 변경은 1.7 의 규칙을 따르며, 표시된 초기값은 설정값으로 관리하여 실측(9.10)과 팀 검증셋(10.8·11.9) 결과로 조정함.

No.	설계 영역	주요 내용	상태
1	분석 모듈 파이프라인	표정·시선·음성·대본 비교·상황 적합성 분석 모듈 구성 및 연결	확정
2	실시간 스트리밍 처리 구조	WebSocket 입력 규임, 지연 최소화, 모델 크기·샘플링 주기	확정(9.1·9.2 처리 구조는 10/7 재측정 후 확정, 모델 크기·세션 한도는 설정값)
3	점수 산출 로직	항목별 가중치, 0~100 점 산출, confidence 산출	확정(기준값은 설정값, 검증셋으로 보정)

No.	설계 영역	주요 내용	상태
4	실시간 코칭 트리거 로직	VAD 기반 노출 시점, 쿨다운, 즉시 코칭 예외, 극적 침묵 억제	확정(초기값은 설정값, 검증셋으로 보정)
5	AI 서버 ↔ API 서버 인터페이스	결과 전달 방식·포맷, detail JSON 키, 실패 처리	확정(메시지 형식 확정본 v1.0)
6	벡터 DB 활용 목적 및 스키마	pgvector 활용 목적, AI 서버 DB 테이블·인덱스·검색 흐름	확정

※ 실시간 코칭 프로토콜(7 장)은 애플리케이션 API 명세서에서 이관한 메시지 형식이며, 처리 구조는 9 장, 코칭 판단은 11 장에서 정의함.

1.2 시스템 구성 및 문서 범위

구성	역할	관련 문서
클라이언트(웹)	원본 영상 청크 업로드(애플리케이션 서버가 발급한 임시 URL 로 S3 에 업로드), 실시간 분석 입력 송신·코칭 표시(Nginx /ws 경유로 AI 서버 연결)	UI/UX 명세서
애플리케이션 서버	회원·세션·업로드·결과 조회·대시보드 REST API, 연결 티켓(JWT) 발급(C03), 원본 영상 관리(S3 임시 URL 발급)	API 명세서
애플리케이션 DB	회원·세션·영상 메타데이터·분석 결과·피드백 저장(데이터베이스 vectoract_app)	DB 설계서
AI 서버	실시간 코칭 연결(7 장), 분석 엔진, LLM·임베딩 실행	본 문서
AI 서버 DB	코칭 문구 벡터, 기대 감정 프로파일. 애플리케이션 서버 PC 의 PostgreSQL 안 별도 데이터베이스(vectoract_ai), 접속 계정 분리	본 문서 6 장, DB 설계서 11 장
서버 간 인터페이스	세션 설정 전달, 분석 요청·결과 전달, 모드 전환·삭제 통보, 기간 피드백	본 문서 8 장, 서버 간 메시지 형식 확정본 v1.0

※ AI 서버 계정은 애플리케이션 DB(vectoract_app)에 접근 권한이 없음. 애플리케이션 API 의 결과 형식(C10-U08 등)은 애플리케이션 서버가 AI 결과로 채우는 형식이므로 서버 간 인터페이스를 통한 간접 제약으로 다름. 서버 배치는 1.5 참고.

1.3 기술 스택

구분	선정 기술	용도
AI 서버	Python 3.12(3.12.3 이상), FastAPI	실시간 코칭 연결(WebSocket), 분석 요청 수신, 스트림·배치 분석 실행
얼굴 특징 추출	Google MediaPipe Face Landmarker	얼굴 랜드마크, 블렌드셰이프, 머리 자세
얼굴 감정 분류	LightGBM	프레임별 7 종 감정 확률

구분	선정 기술	용도
감정 시계열	1 차 규칙 기반 → GRU 교체	감정 안정화, 감정 전환 감지, 얼굴 각성도
발화 감지	Silero VAD	발화-침묵 구간 판정
음향 특징	Librosa	음량, 기본주파수(F0), 억양
음성 감정	emotion2vec+	발화별 감정 확률
음성 인식	faster-whisper	한국어 전사, 단어 타임스탬프, 발화 속도
대본 비교	음절 단위 편집거리 정렬	대본 일치율, 현재 대사 위치 추적·복구
상황 해석·문장 생성	Gemma 4 소형 모델(후보 E4B·12B·26B A4B, 4 비트 양자화), Ollama 로컬 서빙	대사별 기대 감정 프로파일, 결과 문장. 크기는 측정 후 설정값(5.3)
텍스트 임베딩	KURE-v1 (로컬, 1024 차원)	코칭·연습 문구 및 검색 질의 임베딩
AI 서버 DB	PostgreSQL + pgvector (애플리케이션 서버 PC, 별도 데이터베이스 vectoract_ai)	코칭 문구 벡터 검색, 기대 감정 프로파일 저장
메시지 큐	Redis Streams (애플리케이션 서버 PC)	서버 간 메시지(8 장), D07 문구 캐시
웹 서버·HTTPS	Nginx (애플리케이션 서버 PC), Let's Encrypt 인증서	HTTPS·WSS 종료, 프론트 화면·api/ws 연결(1.5)
원본 영상 저장소	AWS S3	원본 보관, 임시 업로드·다운로드 URL(8.7)
서버 하드웨어	학교 AI 서버 km-ai(HP Z8): NVIDIA Quadro RTX 6000 24GB × 1(다른 과제와 공용), CPU 48 코어, RAM 31GB	GPU 배치는 2.5 참고

※ LLM과 임베딩 모델을 모두 학교 AI 서버에서 로컬 실행하므로 대본·상황 설명·분석 결과가 외부 AI 서비스로 전송되지 않음.

AI 모델 구성 표기: 분석 모델 5 종(얼굴 감정 MediaPipe + LightGBM, 음성 인식 faster-whisper, 음성 감정 emotion2vec+, LLM Gemma 4 소형 모델, 텍스트 임베딩 KURE-v1)과 전처리 모델 1 종(발화 감지 Silero VAD)으로 표기함. MediaPipe와 LightGBM은 얼굴 감정 한 종류로 셈.

1.4 준수 제약

기존 문서에서 확정된 아래 제약을 AI 서버 설계의 전제로 함. API 명세 근거 항목은 애플리케이션 서버를 통한 간접 제약임.

항목	확정 내용	근거
분석 항목	expression, voice, gaze, posture, emotion, scriptDelivery, situationFit 7 종. posture는 1 차 범위에서 항상 NOT_SUPPORTED	C10, DB 3.12
점수 형식	0~100(소수 1 자리), confidence 0~1 또는 null, status-reasonCode	FR-AI-07, C10

항목	확정 내용	근거
음성 분석	발화 속도, 음량, 억양, 말투, 음성 감정. 말투는 자연어·의성어를 포함한 발화 전반이며 표준 말투를 두지 않음. 음량 과소 시 즉시 코칭	FR-AI-03
대본 동기화	10 초 이상 불일치 시 전체 대본 재탐색 후 일치율 최고 지점으로 포인터 복구	FR-AI-08
실시간 입력	JPEG 최대 640×360·초당 2 장·256KiB, PCM s16le/mono/16kHz·500ms 단위. 시간은 녹화 시작 기준 ms	7 장
원본 영상	1080p/30fps, 5~10 초 청크 저장, 최대 10 분. 업로드는 최대 2GiB·10 분	FR-RECORD-01-02-05, U01
실행 모드	REALTIME / NEAR_REALTIME / POST_ONLY	API C01, 7 장
준실시간	짧은 구간 순차 분석, 직전 구간 피드백을 다음 구간 촬영 중 제공, 원본 시간축 재매핑	FR-LIVE-06, FR-RECORD-04
실시간 코칭	2~3 초 표시, 쿨다운 15~30 초, VAD 침묵 구간 노출, 극적 침묵 시 재촉 코칭 억제	FR-LIVE-01~03, 요구사항 5.2
결과 표현	근거 불명확 시 과도한 긍정 지양, 신뢰도 낮은 항목 확정적 표현 지양	FR-RESULT-02-03
결과 형식	summary 2000 자, strengths-improvements 각 10 개, segments 300 개, nextPractice 5 개 이하	C10, U08
데이터 보존	실시간 원본 30 일(결과 유지), 업로드 원본 분석 후 삭제·결과 24 시간, 탈퇴 7 일 후 Hard Delete	NFR-DATA-01-02, DB 6
확장성	자세·제스처·발음 정확도 등 분석 항목 확장 가능 구조	NFR-EXT-01
전송 보안	사용자 기기 ↔ 서버 구간은 HTTPS-WSS 로 암호화. 서버 간 구간은 학교 내부망과 접근 제한·계정 인증으로 보호(1.5)	NFR-SEC-07
음성 코칭	선택 기능, 기본값 OFF. ON 이면 짧은 음성으로 코칭 제공(voiceText)	FR-COACH-02, FR-LIVE-04

1.5 서버 배치와 네트워크

모든 서버는 학교 내부망에 두며 외부에는 공개하지 않음(지도교수 결정, 2026. 10. 02). 사용자는 학교 내부 유선망에서 접속하며, 원본 영상만 AWS S3 에 저장함. 학교 서버와 S3 사이는 학교에서 밖으로 나가는 연결만 사용함.

```
[사용자 브라우저] --https://{도메인} (443)--> [교내 PC: Nginx]
| - /      프론트 화면(정적 파일)
| - /api   애플리케이션 서버(같은 PC)
| - /ws    AI 서버 km-ai 10.1.24.173:8804
[교내 PC] 애플리케이션 서버, PostgreSQL(vectoract_app, vectoract_ai), Redis
[km-ai]   AI 서버(FastAPI 8804, 분석 워커, Ollama, KURE-v1) --내부망--> Redis, vectoract_ai
[AWS S3]  원본 영상 <-- 업로드(브라우저, 임시 URL) / 다운로드(AI 서버, 임시 URL)
```

위치	구성	주소·포트
애플리케이션 서버 PC(교내)	Nginx, 애플리케이션 서버, PostgreSQL + pgvector(vectoract_app, vectoract_ai), Redis	내부 IP(설치 후 기재), HTTPS 443
AI 서버 km-ai(교내)	FastAPI 게이트웨이, 분석 워커, Ollama(LLM), KURE-v1	10.1.24.173(고정), 8804(포트 끝자리 = 조 번호 규칙). 내부망 접속 확인 완료
AWS S3	원본 영상(실시간 30 일, 업로드는 분석 후 삭제)	서울 리전, 비공개 버킷

HTTPS 와 도메인

항목	결정	비고
필요성	브라우저는 HTTPS 페이지에서만 카메라·마이크를 허용하므로 내부망 접속에도 HTTPS 가 필요함(NFR-SEC-07)	-
인증서	도메인 1 개 구매 + Let's Encrypt, DNS 인증(DNS-01)	인증 기관이 학교 서버에 접속하지 않으므로 외부 공개 없이 발급 가능. 자동 갱신(90 일). Nginx 에만 설치
이름 연결	공개 DNS 의 A 레코드에 애플리케이션 서버 PC 의 내부 IP 등록	학교 안에서만 접속되고 밖에서는 내부 IP 에 도달할 수 없음
대체 방법	학교 DNS 가 내부 IP 응답을 차단(DNS 리바인딩 차단)하면 학교 사설 DNS 에 등록하거나 시연 기기 hosts 파일에 등록	인증서는 그대로 사용
확인 방법	도메인 등록 후 연구실 PC 에서 nslookup 으로 학교 DNS 와 공개 DNS(8.8.8.8) 응답 비교	12.2
개발 단계	도메인 준비 전에는 사설 인증서(mkcert)로 개발	Nginx 의 인증서 파일만 교체

※ Nginx 의 /ws 경로에는 WebSocket 연결 전환 설정(proxy_http_version 1.1, Upgrade-Connection 헤더 전달)을 둬. /internal 경로(8.6)는 Nginx 로 공개하지 않음.

구간별 보안

구간	방식	접근 제한·인증
브라우저 ↔ Nginx	HTTPS-WSS(TLS)	로그인(애플리케이션), 연결 티켓(7.2)
Nginx → AI 서버(/ws)	내부망 일반 연결(ws)	연결 티켓 JWT(7.2)
애플리케이션 서버 → AI 내부 API	내부망 HTTP	서비스 JWT(8.9)
AI 서버 → Redis	내부망	Redis ACL 계정, 학교 PC 방화벽에서 km-ai IP 만 허용(8.9)

구간	방식	접근 제한·인증
AI 서버 → vectoract_ai	내부망	전용 계정, 방화벽·PostgreSQL 접속 설정에서 km-ai IP 만 허용(6.1)
교내 서버 → AWS S3	HTTPS(밖으로 나가는 연결)	임시 URL(8.7). AWS 키는 애플리케이션 서버 PC 에만 보관

※ 외부 공개가 없는 서버 간 내부망 구간은 TLS 를 쓰지 않고 접근 제한과 계정 인증으로 보호함. NFR-SEC-07 의 '안전한 통신 방식'은 사용자 기기와 서버 사이 구간의 암호화로 충족하는 것으로 해석함(2026. 10. 03 결정).

1.6 운영

항목	내용
서비스 실행	애플리케이션 서버 PC 와 km-ai 모두 서비스(systemd)로 등록하여 부팅 시 자동 실행하고, 비정상 종료 시 자동 재시작함. km-ai 는 지도교수가 부여하는 sudo 권한으로 등록
DB 백업	매일 1 회(새벽) pg_dump 로 vectoract_app·vectoract_ai 를 백업하여 애플리케이션 서버 PC 의 별도 백업 폴더에 보관(초기값 7 일). 가능하면 운영 디스크와 다른 디스크 사용
백업 한계	백업 사본이 학교 PC 에만 있으므로 PC 디스크가 고장 나면 함께 손실될 수 있음(팀 선택, 2026. 10. 03). 원본 영상은 S3 에 있어 영향 없음
Redis	AOF 저장(8.5)으로 재시작 후에도 처리 전 메시지 유지
공용 GPU	km-ai GPU 는 다른 과제와 함께 사용함. 측정·대량 처리는 사용량이 적은 시간에 하고, 다른 사용자의 프로세스는 건드리지 않음
운영 로그	지연 지표(9.4), 모드 전환, 코칭 송신·억제 기록은 운영 로그로만 남기고 DB 에 저장하지 않음

1.7 기준선과 변경 관리

본 판(v1.2)을 개발 기준선으로 함. 단, 9.1-9.2 의 실시간 처리 구조는 10/7 재측정 결과를 확인한 뒤 확정하며, 확정 시 문서 이력에 기록함. 이후 변경은 아래와 같이 구분하여 관리함.

구분	대상	변경 절차
구조·인터페이스	서버 배치(1.5), 모듈 구성(M1~M12), 처리 구조(9.1-9.2), 실시간 코칭 프로토콜(7 장), 서버 간 메시지·API(8 장, 메시지 형식 확정본), AI 서버 DB 테이블(6 장), 점수 지표 정의(10 장), 문제 유형 목록(11.3)	팀장 승인 → 문서 이력 기록 → 문서 버전 올림. 메시지 형식은 schemaVersion 도 올림
설정값	모델 크기·정밀도, LLM 크기, 동시 세션 한도, 지연 목표·모드 전환 조건·대기열 한도, VAD 값, 점수 기준값·가중치, 코칭 감지 조건·쿨다운, 코칭 문구, 각종 시간 초기값(12.1)	설정 파일과 측정·보정 기록만 갱신하고 문서는 개정하지 않음. 점수 기준값은 scoringVersion 으로 관리(10.8)

2. 분석 파이프라인 구성

2.1 전체 구조

분석 파이프라인은 영상 경로, 음성 경로, 통합 단계로 구성함. 영상 경로는 얼굴 특징에서 감정 시계열까지, 음성 경로는 발화 감지를 기점으로 음향 특징·음성 감정·음성 인식을 병렬 처리함. 통합 단계에서 얼굴·음성 감정을 융합하고 대본·상황 기준과 비교하여 최종 결과를 조립함.




그림 1. AI 분석 파이프라인 구성도 (점수 산출용 개별 지표의 M12 전달 화살표는 생략)

2.2 실행 단위

동일 분석 모듈을 세 가지 실행 단위로 구동함. 최종 결과(점수·피드백)는 모든 모드에서 전체 단위 분석으로 생성하며, 스트림·구간 단위 결과는 촬영 중 코칭과 준실시간 피드백에만 사용함(혼합 방식).

실행 단위	적용 대상	입력	사용처
스트림	REALTIME 촬영 중	실시간 코칭 연결(7 장)로 수신한 JPEG 640×360·2fps, PCM 16kHz 500ms 패킷	실시간 코칭 판단(11 장)
구간	NEAR_REALTIME 촬영 중	실시간 코칭 연결 패킷을 10 초 구간으로 묶어 처리(9.6)	직전 구간 피드백(FR- LIVE-06)
전체	촬영 종료 후 사후 분석(전 모드 공통), 업로드 분석(U06)	S3 원본: 음성은 전체 재처리, 영상은 샘플링 재분석	C10-U08 최종 결과

- **일관성:** 실시간·준실시간·POST_ONLY 세션과 업로드 분석이 같은 경로로 최종 결과를 생성하므로 scoringVersion 기준 비교가 일관됨.

- **음성 재처리:** 원본 영상에서 오디오를 추출해 16kHz mono 로 변환한 뒤 M5~M9 를 전체 구간에 다시 적용함.
- **영상 샘플링:** 원본 30fps 에서 초당 5 장을 추출해 M1~M4 를 적용함(9.8).

2.3 공통 시간축 (0.5 초 격자)

- 모든 시계열 특징은 녹화 시작 기준 0.5 초 단위 구간(bin)으로 정렬함. 실시간 영상 2fps, 음성 500ms 패킷과 동일한 간격임.
- 전체 단위 분석에서 한 bin 에 여러 프레임이 있는 경우 얼굴 감정 확률·블렌드셰이프를 bin 평균으로 집계함.
- 감정 시계열 모듈(M4)은 실행 단위와 무관하게 동일한 0.5 초 격자 입력을 받으므로 실시간·사후 분석에서 같은 규칙(추후 같은 GRU 모델)을 사용함.
- 구간 단위 결과는 원본 영상 시간축으로 재매핑함(FR-RECORD-04). 시각 표기는 API 공통 규격과 같이 ms 정수로 함.

2.4 공통 분석 엔진 구조

분석 모듈(M1~M12)과 점수 계산은 하나의 분석 엔진에만 구현하고, 입력 출처는 드라이버로 분리함. 엔진은 입력이 실시간 스트림인지 파일인지 구분하지 않으며, 실행 단위의 차이는 드라이버와 실행 설정으로만 표현함.

구성 요소	내용
실시간 스트림 드라이버	실시간 코칭 연결(7 장)로 클라이언트에서 직접 수신한 JPEG-PCM 패킷을 0.5 초 격자 입력으로 변환하여 엔진에 전달(스트림·구간 단위)
파일 드라이버	S3 원본 또는 업로드 영상을 디코딩하여 설정된 프레임 간격과 16kHz 오디오로 엔진에 전달(전체 단위, 재분석 C11 포함)
실행 설정	영상 프레임 간격, 사용 모듈 목록, 모델 버전, 결과 용도(코칭 판단 / 최종 결과)
분석 엔진	M1~M12 모듈, 점수 계산(10 장). 드라이버와 무관하게 동일 코드로 동작

- **유지보수:** 모듈 수정·모델 교체는 엔진 한 곳에서만 이루어지며, 실시간·사후·업로드 분석에 동시에 적용됨.
- **확장성(NFR-EXT-01):** 제스처처럼 높은 프레임이 필요한 분석이나 무거운 모델(발음 정확도 등)은 파일 드라이버 실행 설정에만 추가하여 실시간 코칭 지연에 영향을 주지 않고 도입할 수 있음.

2.5 GPU 배치

km-ai 의 GPU 는 Quadro RTX 6000(24GB) 1 장이며 다른 과제와 함께 사용함. 분석 모델과 LLM·임베딩을 같은 GPU 에 두고, 실시간 세션의 음성 분석을 가장 먼저 처리함.

구분	담당	GPU 메모리
GPU (Quadro RTX 6000 24GB)	faster-whisper(M8)	large-v3-turbo: int8 약 1.4GB, float16 약 2.3GB(실측, 9.10.1)
	emotion2vec+(M7)	base 약 0.7GB, large 약 1.0GB(실측, 9.10.1)
	KURE-v1 임베딩	약 1GB 대(예상, 10/7 측정)
	LLM(Ollama, Gemma 4 소형 4 비트)	목표 10GB 이하(후보별 측정 후 결정, 5.3)
CPU	MediaPipe, LightGBM, Silero VAD, Librosa(음량·F0), 대본 정렬	-

※ 분석 모델 합계는 약 3~4GB 로 측정됨. 다른 과제의 사용량(refit-ai 약 14GB 는 정리 예정)에 따라 LLM 에 쓸 수 있는 공간이 달라지므로 LLM 크기는 설정값으로 관리함(1.7).

※ 이 GPU(Turing 세대)는 bf16 연산을 지원하지 않으므로 float16-int8·4 비트 양자화로 실행함. 실시간 세션이 있는 동안 LLM 작업은 동시 1 건(초기값)으로 제한하고 음성 모델 작업을 먼저 처리함(9.1).

3. 분석 모듈 상세

3.1 모듈 목록

ID	모듈	기술	주요 출력	스트림	전체
M1	얼굴 특징 추출	MediaPipe	얼굴 검출 여부, 블렌드셰이프, 머리 자세, 홍채 위치	O	O
M2	시선 분석	M1 파생	시선 방향, 시선 유지 비율, 이탈 구간	O	O
M3	얼굴 감정 분류	LightGBM	프레임별 7 종 감정 확률	O	O
M4	감정 시계열	규칙 → GRU	안정화 감정, 감정 전환, 얼굴 각성도	O	O
M5	발화 감지	Silero VAD	발화·침묵 구간	O	O
M6	음향 특징	Librosa	음량, F0, 억양, 음성 각성도 요소	O	O
M7	음성 감정	emotion2vec+	발화별 7 종 감정 확률	O	O
M8	음성 인식	faster-whisper	전사, 단어 타임스탬프, 발화 속도	O	O
M9	대본 정렬	음절 편집거리	대사별 일치율, 현재 대사 위치, 대사별 시간 구간	O	O
M10	감정 융합	가중 평균	융합 감정 분포, 각성도	O	O
M11	상황 적합성	LLM 프로파일 비교	대사별 적합도, 불일치 구간	O	O
M12	결과 조립·문장 생성	LLM, V-A	C10-U08 결과	-	O

※ 구간 단위(NEAR_REALTIME)는 스트림 단위와 같은 모듈과 같은 입력(실시간 코칭 연결 패킷)을 사용함(9.6). M11 의 스트림 단위 적용은 기대 감정 프로파일 생성이 완료된 경우에 한함.

M1. 얼굴 특징 추출 (MediaPipe Face Landmarker)

구분	내용
입력	영상 프레임(스트림: 실시간 코칭 연결로 수신한 JPEG, 전체: 원본에서 샘플링한 프레임)
처리	얼굴 검출, 3D 랜드마크 478 점(홍채 포함), 블렌드셰이프 52 종, 얼굴 변환 행렬 추출
출력	face_detected, blendshapes[52], head_pose(yaw·pitch·roll), 홍채 랜드마크
연결	FR-AI-01-02, 즉시 코칭 '얼굴 이탈'(UI 6.5)
비고	원시 랜드마크 좌표는 개인 식별 가능성이 있는 생체정보 성격이므로 메모리 내 처리 후 폐기하며 DB 에 저장하지 않음

M2. 시선 분석

구분	내용
입력	M1 홍채 랜드마크, 머리 자세
처리	눈 영역 내 홍채 위치로 시선 방향 산출, 머리 자세로 보정, 0.5 초 bin 단위 시선 유지 여부 판정
출력	시선 방향, 시선 유지 비율, 시선 이탈 구간
연결	FR-AI-02, gaze
비고	시선 이탈 판정 기준(초기값): 머리 자세로 보정한 시선 방향이 카메라 방향에서 수평 $\pm 15^\circ$, 수직 $\pm 10^\circ$ 를 벗어남. 10.8 에서 보정

M3. 얼굴 감정 분류 (LightGBM)

구분	내용
입력	M1 블렌드셰이프 52 종, 머리 자세
처리	프레임별 7 종 감정 분류(4.1 라벨 체계)
출력	p_face[7], 프레임별 신뢰도(최대 확률)
학습	공개 표정 데이터셋 + AI Hub '한국인 감정인식을 위한 복합 영상' 일부(4.3 매핑). 원본 이미지에 MediaPipe 를 적용해 추출한 블렌드셰이프를 학습 특징으로 사용
검증	팀 촬영 검증셋 세트 A(7 종 감정 클립, 4.6)로 실사용 성능 측정, 발표 자료에 활용
연결	FR-AI-01, expression, emotion

M4. 감정 시계열 (1 차 규칙 기반 → GRU 교체)

구분	내용
입력	0.5 초 bin 단위 M3 확률, 블렌드셰이프 bin 평균, 머리 움직임량

구분	내용
출력	① 안정화 감정 분포 p_face_smooth[7] ② 감정 전환 이벤트(시각, 이전 감정 → 이후 감정) ③ 얼굴 각성도 arousal_face(0~1)
1 차 규칙	① 지수 평활로 bin 별 확률 안정화 ② 우세 감정 변경 후 일정 bin 이상 유지 시 전환으로 확정 ③ 블렌드셰이프 활성 강도·머리 움직임량을 세션 기준으로 정규화하여 각성도 산출 평활 계수·유지 bin 수·정규화 방식은 팀 촬영 검증셋으로 결정
GRU 교체	입력·출력 형식을 1 차 규칙과 동일하게 유지하여 모듈 단위로 교체함. 학습 데이터 확보 후 진행
연결	FR-AI-01, FR-AI-05, FR-LIVE-03(극적 상태 판단), UI 10.5 '감정 전환'

M5. 발화 감지 (Silero VAD)

구분	내용
입력	PCM 16kHz mono(스트림: 500ms 패킷, 전체: 원본에서 추출·변환한 오디오)
출력	발화 구간 [startMs, endMs], 침묵 구간, bin 별 발화 여부
연결	FR-LIVE-03 코칭 노출 시점(11.5), M6~M8 처리 단위
설정(초기값)	threshold 0.18, 최소 발화 300ms, 최소 무음 200ms, 앞뒤 여유(padding) 350ms. 독백 연기 영상 8 개로 비교·선정하여 Micro F1 0.826(팀 튜닝). 설정값으로 관리(1.7)
비고	연기의 속삭이는 대사까지 감지하도록 기준을 낮게 잡음. 튜닝 평가 기준과 실시간 스트림 적용 시 동작은 후속 확인(12.2)

M6. 음향 특징 (Librosa)

구분	내용
처리	RMS 기반 음량(dBFS), pYIN 기반 F0 곡선, 발화별 F0 변화폭(억양), 음량·F0 변동 기반 음성 각성도 요소 산출
출력	bin 별 음량·F0, 발화별 억양 지표, arousal_voice 구성 요소
연결	FR-AI-03(음량·억양), voice, 즉시 코칭 '음성 과소'(UI 6.5)
비고	실시간 스트림에서 음량은 500ms 패킷마다, F0 는 발화 종료 시 발화 단위로 계산함(9.2). 따라서 실시간 각성도의 F0 요소는 발화 종료 후 반영됨

M7. 음성 감정 (emotion2vec+)

구분	내용
입력	M5 발화 구간 오디오(16kHz). 의성어·감탄사 등 비언어 발성 구간 포함

구분	내용
처리	발화(utterance) 단위 추론, 9 종 출력을 7 종 라벨로 매핑(4.2). other-unknown 확률은 신뢰도 감점 요소로 사용
출력	발화별 p_voice[7], 음성 감정 신뢰도
연결	FR-AI-03(음성 감정), emotion
비고	base-large 모두 1 차 실측(9.10.1)에서 자연 목표를 충족함. 초기값 base, 세트 A 촬영 후 정확도 비교로 결정(설정값). 한국어 성능은 KEMDy20 으로 검증. 라이선스는 졸업작품 범위에서 사용 가능

M8. 음성 인식 (faster-whisper)

구분	내용
입력	M5 발화 구간 오디오
처리	한국어 전사, 단어 단위 타임스탬프 추출
출력	전사 텍스트, 단어 타임스탬프, 발화 속도(발화 구간 기준 음절/초)
연결	FR-AI-03(발화 속도), FR-AI-04, voice, scriptDelivery
비고	스트림 단위에서는 발화 종료 시점마다 처리함. 1 차 실측(9.10.1)으로 large-v3-turbo 선정(발화당 전사 p95 약 0.31 초), 연산 정밀도 초기값 int8_float16(설정값). 긴 발화의 최대 처리 길이는 설정값

M9. 대본 정렬 (음절 단위 편집거리)

구분	내용
입력	대본(scriptContent), M8 전사 결과
처리	공백·문장부호 제거 후, 대본에 없는 의성어·감탄사(한숨·흐느낌·웃음 등)는 정렬 대상에서 제외하고 음절 단위 정렬. 평상시에는 현재 대본 위치 주변 구간만 비교하고, 불일치가 10 초 이상 지속되면 전체 대본을 스캔하여 일치율이 가장 높은 지점으로 포인터를 복구함. 일치 지점 미탐색 시 기존 위치 유지
출력	대사별 일치율, 누락·추가·치환 위치(의성어·감탄사 제외), 현재 대사 위치, 대사별 시간 구간
연결	FR-AI-04-08, scriptDelivery. 대사별 시간 구간은 M11 비교 기준으로 사용
비고	말투 정의(FR-AI-03)에 따라 의성어·감탄사는 대본 오류로 집계하지 않음. 제외 대상 판별 목록(의성어·감탄사 사전)은 구현 시 정의. 어미 변형·애드리브는 불일치로 집계되는 한계가 있음. 복구 판정 기준(초기값): 전체 대본 재탐색 결과 일치율 0.6 이상일 때만 포인터 이동

M10. 감정 융합 (가중 평균)

구분	내용
입력	M4 안정화 감정 분포·얼굴 각성도, M7 발화별 감정 분포, M6 음성 각성도 요소

구분	내용
처리	0.5 초 bin 단위로 얼굴·음성 감정 확률을 신뢰도 가중 평균함. 발화가 없는 bin 은 얼굴 결과만 사용. 각성도도 같은 방식으로 결합
출력	융합 감정 분포 p_fused[7], 우세 감정, 각성도 arousal(0~1)
비고	융합 가중치 = 기본 가중치(초기값 얼굴 0.5, 음성 0.5) × 각 신뢰도. 음성 신뢰도는 (1 - other-unknown 확률 합) × 재정규화 최대 확률. 10.8 에서 보정. 추후 GRU 입력 단계 융합으로 확장 가능

M11. 상황 적합성 (기대 감정 프로파일 비교)

구분	내용
입력	LLM 기대 감정 프로파일(5 장), M9 대사별 시간 구간, M10 관측 감정·각성도
처리	대사별 시간 구간 동안의 관측 감정·각성도를 기대값과 비교
출력	대사별 적합도, 기대와 어긋난 구간
연결	FR-SCRIPT-04, FR-AI-05, situationFit
실패 처리	프로파일 생성 실패 시 촬영은 그대로 진행하고 situationFit 은 status=UNAVAILABLE 과 reasonCode 로 처리

M12. 결과 조립 및 문장 생성

구분	내용
입력	M1~M11 결과, 항목별 점수(10 장), V-A 검색 문구(6 장)
처리	점수와 구간 피드백을 구성하고 피드백마다 category 와 세부 항목 코드(3.3)를 부여한 뒤, LLM 이 V-A 검색 문구를 근거로 summary, strengths, improvements, segments 의 message-suggestion, nextPractice 문장을 작성
출력	ANALYSIS_RESULT 메시지(8.3)로 애플리케이션 서버에 전달
제약	API 길이·개수 제한 준수. 신뢰도 낮은 항목은 확정적 표현 지양, 근거 없는 긍정 평가 지양(FR-RESULT-02-03)
비고	LLM 호출 실패 시 결과 문장을 템플릿으로 대체하고 점수·구간 피드백은 정상 전달(8.3)

3.2 분석 항목별 모듈 매핑

API 항목	사용 모듈	주요 지표(detail 저장 후보)	비고
expression	M1, M4	얼굴 가시 비율, 표정 활성화도, 무표정 정지 비율	
voice	M5, M6, M8	발화 속도 안정성, 평균 음량, 클리핑 비율, 억양 변화폭	말투는 voice-emotion 지표 전체로 평가(표준 말투 없음)

API 항목	사용 모듈	주요 지표(detail 저장 후보)	비고
gaze	M1, M2	시선 유지 비율, 이탈 구간	
posture	없음	없음	1 차 범위 NOT_SUPPORTED 고정
emotion	M3, M4, M7, M10	대사별 감정 일치도, 감정 전환 성공률	
scriptDelivery	M8, M9	대본 일치율, 누락·추가·치환 수	
situationFit	M6, M9, M10, M11	대사별 각성도 적합, 운율 적합	프로파일 없으면 UNAVAILABLE

※ 세부 지표 정의와 계산식은 10 장을 따르며, 세부 지표 값은 ANALYSIS_RESULT(8.3)의 scores[].detail 에 세부 지표 이름(E1, V2 등)을 키로 담아 전달함.

3.3 세부 항목 코드

누적 취약점 화면(UI 10.5)의 세부 항목 집계를 위해, AI 서버는 모든 구간 피드백에 category 와 함께 세부 항목 코드를 부여함. 애플리케이션 DB 의 analysis_feedbacks.subcategory 와 API D07 items[].subItems[]에 대응함.

category	세부 항목 코드	UI 10.5 표시명	판정 근거 모듈
EXPRESSION	FACIAL_EXPRESSION	표정	M1, M3, M4
GAZE	GAZE_HOLD	시선	M2
VOICE	SPEECH_RATE	발화 속도	M8
VOICE	VOLUME	음량	M6
VOICE	INTONATION	억양	M6
EMOTION	EMOTION_EXPRESSION	감정 표현	M3, M7, M10
EMOTION	EMOTION_TRANSITION	감정 전환	M4, M10
SCRIPT_DELIVERY	SCRIPT_ACCURACY	대본 전달	M9
SITUATION_FIT	SITUATION_FIT	상황 적합성	M11

※ POSTURE 는 1 차 범위 미지원으로 피드백을 생성하지 않음. API D07 은 같은 코드를 camelCase(예: speechRate)로 표기함.

4. 감정 라벨 및 각성도 정의

4.1 감정 라벨

AI 서버 내부 감정 라벨은 국제 표준 7 종으로 정의함. 얼굴 감정(M3), 음성 감정(M7), 감정 시계열(M4), 기대 감정 프로파일(M11)이 모두 이 체계를 공통으로 사용함.

코드값	표시명	비고
JOY	기쁨	
SADNESS	슬픔	
ANGER	분노	
FEAR	공포	AI Hub '불안' 근사 매핑 포함
SURPRISE	놀람	공개 데이터로만 학습
DISGUST	혐오	공개 데이터로만 학습
NEUTRAL	중립	

4.2 emotion2vec+ 출력 매핑

출력 index	emotion2vec+ 라벨	매핑 코드값
0	angry	ANGER
1	disgusted	DISGUST
2	fearful	FEAR
3	happy	JOY
4	neutral	NEUTRAL
5	other	판정 제외(신뢰도 감점 요소)
6	sad	SADNESS
7	surprised	SURPRISE
8	unknown	판정 제외(신뢰도 감점 요소)

※ 7 종 확률만 합이 1 이 되도록 재정규화하며, other-unknown 확률은 음성 감정 신뢰도를 낮추는 데 사용함(M10 비교).

4.3 얼굴 학습 데이터 라벨 매핑

데이터	원본 라벨	매핑
공개 표정 데이터셋 (RAF-DB, AffectNet, FER2013 등)	happiness, sadness, anger, fear, surprise, disgust, neutral (AffectNet 의 contempt 제외)	동일 의미의 코드값으로 1:1 매핑
AI Hub 한국인 감정인식을 위한 복합 영상	기쁨, 분노, 슬픔, 중립	JOY, ANGER, SADNESS, NEUTRAL
	불안	FEAR (근사 매핑)
	당황, 상처	대응 코드 없음 → 학습 제외

※ SURPRISE-DISGUST 는 공개 데이터로만 학습되므로 클래스별 성능 편차를 팀 촬영 검증셋으로 확인함. 각 데이터셋은 졸업작품 범위에서 사용 가능함(상용화 시 재검토).

4.4 각성도

- 감정 라벨과 별도로 감정의 강도를 나타내는 내부 연속값(0~1)으로 정의함.
- 얼굴 각성도(M4)와 음성 각성도(M6 음량·F0 변동, M7 감정 확률)를 M10 에서 가중 평균으로 결합함.
- 용도: 극적 침묵 판단(FR-LIVE-03, 11.6), 기대 각성도와 비교(M11).
- 음성 각성도는 KEMDy20 의 각성도 평가값으로 검증함.

4.5 저장 및 노출

- 감정 코드값과 각성도는 API 로 노출하지 않음. API 의 emotion 은 점수(0~100)로만 제공되며, 사용자에게는 한국어 표시명을 사용한 피드백 문장으로만 전달됨.
- 세부 값은 AI 서버가 분석 결과와 함께 애플리케이션 서버로 전달하고, 애플리케이션 서버가 애플리케이션 DB 의 기존 JSONB 컬럼(analysis_scores.detail, analysis_feedbacks.detail, analyses.raw_result)에 저장함. 전달 형식은 8.3 ANALYSIS_RESULT 를 따름.

4.6 팀 검증셋

분석 모델과 기준값을 실제 웹캠 환경에서 확인·보정하기 위해 섭외한 테스터가 촬영하는 검증용 영상·음성임. 모델 학습에는 사용하지 않으며, 촬영 환경·파일 규격·문제 카드·평가 양식·검증용 대본은 별도 문서 「검증 영상 촬영 가이드」를 따름.

세트	구성(테스터 1 인)	용도
A. 감정 클립	7 종 감정 × 표정만/대사 2 버전, 각 약 15 초	얼굴·음성 감정 모델 검증(M3·M7), 4.3 매핑의 클래스별 성능 확인

세트	구성(테스터 1인)	용도
B. 대본 연기	검증용 대본 3종 × 정상 1회 + 문제 카드 버전 2회, 문제 구간 시각 기록	점수 기준값 보정(10.8), 코칭 기준 보정(11.9)
C. 대본 낭독	검증용 대본 3종 평소 속도 낭독	음성 인식 모델 크기 결정(9.10), 기본 발화 속도 산출(11.3)

- **평가:** 팀원 2명이 세트 B를 항목별 ' 좋음·보통·부족'으로 독립 평가하고, 세트 A는 의도 감정으로 보이는지 확인하여 전달되지 않은 연기를 모델 오류에서 제외함.
- **보관:** 테스터 동의를 받아 팀 내부 검증 용도로만 보관하며, 프로젝트 종료 후 삭제함.

5. LLM 활용 설계

5.1 호출 시점

호출	시점	입력	출력	실시간 영향
기대 감정 프로파일 생성	실시간: 애플리케이션 서버가 세션 준비(C01)를 처리한 뒤 요청 업로드: 애플리케이션 서버가 U06 접수 후 요청	대본, 상황 설명	대사별 기대 감정(7종 코드), 기대 각성도	없음(촬영 중 호출 없음)
결과 문장 생성	사후 분석 마지막 단계(M12)	점수, 구간 결과, V-A 검색 문구	summary, strengths, improvements, segments 문장, nextPractice	없음(결과 대기 시간 증가)
기간 피드백 생성	SUMMARY_REQUEST 수신 시(8.8)	주간·월간 통계	D05-D06 summary 문장	없음(비동기)

5.2 처리 원칙

- **비동기 생성:** AI 서버는 생성 요청을 접수만 하고 즉시 응답하며, 애플리케이션 서버의 C01 응답은 LLM 완료를 기다리지 않음. 카메라 준비 시간 동안 생성을 완료하는 것을 목표로 하며, 촬영 시작 시점까지 완료되지 않으면 촬영은 진행하고 상황 적합성 관련 실시간 코칭만 보류함. 사후 분석은 프로파일 생성 완료 후 수행함.
- **재현성 통제:** 점수 산출에는 기대 감정 프로파일만 사용하며 결과 문장은 점수에 영향을 주지 않음. LLM 출력은 정해진 JSON 구조로 받아 코드값·범위를 검증함.
- **프로파일 재사용:** 재분석(C11) 시 결과가 달라지지 않도록 최초 생성한 프로파일을 저장해 재사용함. AI 서버 DB의 situation_profiles에 저장함(6.6).

- **전송 범위:** LLM에는 대본, 상황 설명, 분석 요약 텍스트만 전달하며 영상·음성 원본은 전달하지 않음.
LLM을 로컬에서 실행하므로 외부 전송은 없음. 추후 LLM·임베딩을 외부 API로 전환하는 경우
개인정보처리방침에 반영해야 함(팀 합의).

5.3 모델 및 서빙

항목	내용
모델	Gemma 4 소형 모델(Google 공개 가중치 모델, 한국어 포함 다국어 학습). 후보: E4B(유효 약 4.5B), 12B, 26B A4B(MoE, 활성 약 3.8B)
선택 기준	10/7 측정으로 ① GPU 메모리(목표 10GB 이하) ② 기대 감정 프로파일 생성 시간(카메라 준비 시간 안, 초기 목표 30 초 이하) ③ JSON 구조화 출력 성공률 ④ 결과 문장 품질(팀 평가)을 비교하여 선택. 선택한 모델은 설정값으로 관리(1.7)
정밀도	4 비트 양자화 기준. GPU가 bf16을 지원하지 않으므로 bf16 그대로는 사용하지 않음(2.5)
서빙	Ollama, 분석 모델과 같은 GPU 사용(2.5). 실시간 세션이 있는 동안 LLM 작업 동시 실행 1 건(초기값)
호출 방식	Ollama의 OpenAI 호환 API로만 호출. 추후 다른 로컬 모델이나 외부 API로 교체 시 AI 서버 코드 변경 최소화
구조화 출력	기대 감정 프로파일은 JSON 스키마를 지정한 구조화 출력으로 생성하고, 수신 후 코드값·범위를 재검증
입력 길이	대본 최대 20,000자를 처리할 수 있도록 컨텍스트 길이(num_ctx)를 명시적으로 설정. 기본값 사용 시 긴 대본이 잘릴 수 있음
외부 API	사용하지 않음(2026. 10. 03 결정). 전환하려면 개인정보처리방침 반영이 필요함(13 장 EXT)

6. AI 서버 DB 설계

6.1 구성

AI 서버 DB는 애플리케이션 서버 PC의 PostgreSQL(+pgvector) 안에 별도 데이터베이스(vectoract_ai)로 둬(2026. 10. 02 결정). 애플리케이션 DB(vectoract_app)와 접속 계정을 분리하여 AI 서버 계정은 vectoract_ai에만 권한을 가지며, AI 서버는 학교 내부망으로 접속함(1.5). 애플리케이션 쪽 식별자(sessionId 등)는 외래 키 없이 값으로만 보관함.

테이블	용도	개인 데이터	관련 절
coaching_phrases	팀이 작성한 코칭·연습 제안 문구와 임베딩(V-A 벡터 검색). 스키마 정보는 DB 설계서 11 장	없음	6.2~6.5
situation_profiles	LLM이 생성한 대사별 기대 감정 프로파일(재분석 시 재사용)	있음(대본·상황에서 파생)	6.6~6.7

6.2 벡터 검색 활용 목적

팀이 작성한 코칭·연습 제안 문구 라이브러리를 텍스트 임베딩으로 저장하고, 분석에서 감지된 문제 상황과 의미가 가장 가까운 문구를 검색함(V-A). 새로운 사용자 기능을 추가하지 않고, 기존 결과 필드에 들어갈 문구의 품질과 일관성을 높이는 내부 수단으로 사용함.

용도	사용 위치	대상 필드	연결 요구사항
실시간 코칭 문구	실시간 코칭 이벤트(11.7)	COACHING.message(1~120 자), voiceText (7 장)	FR-LIVE-01-04, NFR-UX-04
구간 연습 제안	M12	segments[].suggestion(최대 500 자)	FR-RESULT-04
다음 연습 추천	M12	nextPractice[] (각 최대 500 자)	FR-RESULT-06
누적 취약점 개선 방향	애플리케이션 대시보드 집계	D07 items[].suggestion(최대 500 자)	FR-DASH-05

※ D07 은 애플리케이션 서버가 애플리케이션 DB 에서 집계하므로, V-A 문구는 D07 집계 시 AI 서버 내부 API 로 받아 사용하며(8.6), AI 서버 응답이 없으면 최근 문구 또는 기본 문구로 대체함.

6.3 설계 원칙

- **문구 테이블에 개인 데이터 미저장:** 사용자 영상·음성·분석 결과는 벡터화하지 않음.
coaching_phrases 는 탈퇴·업로드 결과 삭제 등 사용자 데이터 삭제 정책의 적용 대상이 아님.
- **팀 작성 문구만 저장:** 문구는 팀이 작성·검수하며, 별도 관리 화면 없이 적재 스크립트로 관리함.
- **실시간 지연 최소화:** 실시간 코칭용 후보는 세션 시작 시 해당 세션 조건(코칭 강도 등)으로 미리 조회해 메모리에 캐시하고, 촬영 중에는 DB 를 조회하지 않음.

6.4 검색 흐름

1. **질의 생성:** 분석 항목(category)과 세부 항목(subcategory), 문제 유형 코드, 감정·각성도 맥락, 해당 대사를 조합해 질의 문장을 만들고 임베딩함.
2. **조건 필터:** category, subcategory, usage, 코칭 강도, 활성 여부로 후보를 제한함.
3. **유사도 검색:** 코사인 거리 기준 상위 k 개를 조회함.
4. **활용:** 실시간 코칭은 최상위 문구를 사용하고, 사후 분석은 상위 k 개를 LLM 문장 생성의 근거로 제공함.

6.5 테이블: coaching_phrases

coaching_phrases 의 컬럼·제약·인덱스·DDL 은 DB 설계서 11 장(AI 서버 DB)을 정본으로 하며, 본 문서에는 검색에 쓰이는 구성만 요약함.

구분	컬럼	용도
검색 필터	category, subcategory, usage, kind, issue_code, emotion_code, intensity, is_active	6.4 의 조건 필터
문구	content(최대 500 자, 실시간 코칭은 120 자), voice_text(최대 120 자)	결과 필드·코칭 이벤트에 사용
벡터	embedding VECTOR(1024), embedding_model	KURE-v1 임베딩, HNSW(코사인) 인덱스
관리	phrase_version, created_at, updated_at	문구 개정 관리(6.9)

검색 쿼리 예시

```
SELECT id, content, voice_text,
       1 - (embedding <=> $1) AS similarity
FROM coaching_phrases
WHERE is_active
      AND category = $2
      AND (subcategory IS NULL OR subcategory = $3)
      AND usage = $4
      AND (intensity IS NULL OR intensity = $5)
ORDER BY embedding <=> $1
LIMIT $6;
```

※ <=> 는 pgvector 의 코사인 거리 연산자임.

6.6 테이블 설계: situation_profiles

LLM 이 생성한 기대 감정 프로파일(5 장)을 저장하여, 사후 분석과 재분석(C11)에서 같은 프로파일을 재사용함. 대본·상황 설명 원문은 저장하지 않고, 분석 시점에 애플리케이션 서버로부터 전달받음.

컬럼	자료형	NULL	키/제약	설명
id	UUID	N	PK	프로파일 식별자
source	VARCHAR(30)	N	CHECK	LIVE_CAPTURE / UPLOADED_VIDEO
session_id	UUID	Y	UNIQUE(부분)	애플리케이션 sessionId 값(LIVE_CAPTURE)
analysis_id	UUID	Y	UNIQUE(부분)	애플리케이션 analysisId 값(UPLOADED_VIDEO)
user_id	UUID	N		애플리케이션 userId 값. 탈퇴 시 일괄 삭제 기준
status	VARCHAR(20)	N	CHECK	PENDING / READY / FAILED
profile	JSONB	Y		대사별 기대 감정(7 종 코드)·기대 각성도. READY 일 때 필수
llm_model	VARCHAR(100)	N		생성 모델 식별자(예: gemma4-12b-q4)
failure_code	VARCHAR(100)	Y		생성 실패 사유
expires_at	TIMESTAMPTZ	Y		삭제 예정 시각(6.7)
created_at	TIMESTAMPTZ	N	DEFAULT now()	생성 시각

컬럼	자료형	NULL	키/제약	설명
updated_at	TIMESTAMPZ	N	DEFAULT now()	수정 시각

DDL

```
CREATE TABLE situation_profiles (
  id          UUID PRIMARY KEY DEFAULT gen_random_uuid(),
  source      VARCHAR(30) NOT NULL
    CHECK (source IN ('LIVE_CAPTURE', 'UPLOADED_VIDEO')),
  session_id  UUID,
  analysis_id UUID,
  user_id     UUID NOT NULL,
  status      VARCHAR(20) NOT NULL DEFAULT 'PENDING'
    CHECK (status IN ('PENDING', 'READY', 'FAILED')),
  profile     JSONB,
  llm_model   VARCHAR(100) NOT NULL,
  failure_code VARCHAR(100),
  expires_at  TIMESTAMPZ,
  created_at  TIMESTAMPZ NOT NULL DEFAULT CURRENT_TIMESTAMP,
  updated_at  TIMESTAMPZ NOT NULL DEFAULT CURRENT_TIMESTAMP,
  CHECK (
    (source = 'LIVE_CAPTURE' AND session_id IS NOT NULL AND analysis_id IS NULL)
    OR
    (source = 'UPLOADED_VIDEO' AND session_id IS NULL AND analysis_id IS NOT NULL)
  ),
  CHECK (status <> 'READY' OR profile IS NOT NULL)
);

CREATE UNIQUE INDEX uq_situation_profiles_session
  ON situation_profiles(session_id) WHERE session_id IS NOT NULL;
CREATE UNIQUE INDEX uq_situation_profiles_analysis
  ON situation_profiles(analysis_id) WHERE analysis_id IS NOT NULL;
CREATE INDEX idx_situation_profiles_user ON situation_profiles(user_id);
CREATE INDEX idx_situation_profiles_expires
  ON situation_profiles(expires_at) WHERE expires_at IS NOT NULL;
```

6.7 데이터 보존·삭제 동기화

situation_profiles 는 사용자 데이터에서 파생된 정보이므로 애플리케이션의 보존·삭제 정책을 따름. AI 서버는 애플리케이션 DB 를 조회할 수 없으므로, 아래 사건은 애플리케이션 서버의 통보 또는 AI 서버의 만료 시각으로 처리함.

애플리케이션 사건	근거	AI 서버 처리
연습 기록 삭제(D04), 연습 취소(C08)	DB 6 장	통보 수신 시 해당 session_id 프로파일 삭제
실시간 원본 영상 30 일 만료	NFR-DATA-01	재분석이 불가능해지므로 expires_at(촬영 시작 + 30 일) 도달 시 삭제
업로드 분석 결과 24 시간 만료	FR-UPLOAD-03, U08	expires_at(분석 종료 + 24 시간) 도달 시 삭제
회원 탈퇴 Hard Delete(탈퇴 + 7 일)	NFR-DATA-02	통보 수신 시 해당 user_id 의 프로파일 일괄 삭제

※ 저장·삭제 방식은 본 절의 통보 기반 삭제로 확정함. 통보는 DATA_DELETE 메시지(8.3)로 받으며, 삭제 실패 시에는 DB 설계서 6 장과 같이 재처리 가능한 상태를 유지함(요구사항 5.3).

6.8 임베딩 모델

항목	내용
모델	KURE-v1 (고려대 NLP&AI 연구실, BGE-M3 기반 한국어 검색 특화 미세조정 모델, MIT 라이선스)
출력	1024 차원 단일 벡터(dense)
실행	AI 서버 GPU 에서 로컬 실행(2.5). 문구 적재 시와 질의 생성 시 동일 모델 사용
버전 선택 사유	후속 버전 KURE-v2 는 토큰별 다중 벡터(late-interaction) 구조로 pgvector 단일 벡터 컬럼에 맞지 않아 v1 을 사용

6.9 운영 규칙

- 문구를 수정하면 phrase_version 을 올리고 임베딩을 다시 생성함.
- 임베딩 모델을 교체하면 전체 문구를 다시 임베딩하며, 검색 시 질의 임베딩과 저장 임베딩의 embedding_model 이 같아야 함.
- 분석 엔진은 coaching_phrases 를 읽기 전용으로 사용하며, 적재·수정은 관리 스크립트로만 수행함.

6.10 검토 후 제외한 활용안

활용안	제외 사유
V-B. 감정 표현 레퍼런스 매칭	얼굴 감정 분류를 LightGBM(M3)이 담당하게 되어 역할이 중복됨
V-C. 사용자 과거 구간 검색	개인 얼굴 기반 데이터를 저장해야 해 탈퇴·삭제·업로드 제외 정책 적용 부담이 크고, 누적 취약점(D07)은 기존 피드백 집계로 구현 가능함
대본 위치 복구용 문장 검색	세션당 대본이 최대 2 만 자라 메모리 내 탐색으로 충분하며, DB 조회는 실시간 지연만 증가시킴
원시 얼굴 랜드마크 벡터화	개인 식별 가능한 생체정보 성격이며 검색 목적이 불분명함

7. 실시간 코칭 프로토콜

클라이언트는 촬영 중 AI 서버에 직접 WebSocket 으로 연결하여 분석 입력을 보내고 코칭 이벤트를 받음. 본 프로토콜은 기존 애플리케이션 API 명세서의 '실시간 코칭' 절을 AI 서버 설계서로 이관한 것이며, 메시지 형식은 그대로 유지하고 SESSION_STATUS 만 삭제함(7.7).

7.1 연결 절차

- 클라이언트가 애플리케이션 서버의 C03(연결 티켓 발급)을 호출하여 ticket 과 websocketUrl 을 받음.
websocketUrl 은 같은 도메인의 /ws 경로이며 Nginx 가 AI 서버(8804)로 전달함(1.5).
- WSS {websocketUrl}/ws/coaching-sessions/{sessionId}, subprotocol vectoract.v1 로 AI 서버에 연결함.

3. 연결 후 5 초 안에 AUTH 로 티켓을 보내고, AI 서버가 검증(7.2)하면 AUTHENTICATED 를 받음. 티켓은 30 초 유효·1 회 사용이며, 재연결 시 새 티켓을 사용함.

7.2 연결 티켓(JWT) 검증

C03 티켓은 애플리케이션 서버가 개인키로 서명한 짧은 JWT 임. AI 서버는 공개키만 보관하여 서버 간 호출 없이 직접 검증하며, 티켓을 새로 발급할 수 없음.

클레임	값	AI 서버 검증
sub	애플리케이션 userId	세션 소유자 식별(로그·삭제 동기화 기준)
sid	애플리케이션 sessionId	연결 경로의 {sessionId}와 일치해야 함
aud	ai-server	AI 서버 전용 티켓인지 확인
iat / exp	발급 시각 / 발급 + 30 초	만료 여부 확인
jti	티켓 고유 식별자	사용된 jti 를 만료 시까지 보관하여 재사용 차단(1 회 사용)

- **서명 방식:** 비대칭 서명(RS256 또는 ES256). 키 교체에 대비해 JWT 헤더의 kid 로 공개키를 식별함.
- **Access Token 미사용:** 애플리케이션 API 전체에 쓰이는 Access Token(15 분)은 AI 서버로 보내지 않음. 브라우저 WebSocket 은 인증 헤더를 붙일 수 없어 토큰 노출 위험이 크기 때문임.
- **검증 실패:** 서명·클레임 오류는 종료 코드 4401, 세션 불일치는 4403 으로 연결을 종료함.

7.3 메시지

공통 필드(모두 필수): type:string, eventId:UUID, sessionId:UUID, sequence:integer≥0, occurredAt:UTC 시각, payload:object.

방향·type	payload 필드(모두 필수, null 별도 표기)
C→S AUTH	ticket:string
S→C AUTHENTICATED	analysisMode:string(REALTIME/NEAR_REALTIME/POST_ONLY)
C→S PING / S→C PONG	nonce:string(1~64 자)
C→S MEDIA_META	packetId:UUID, kind:string(VIDEO_FRAME/AUDIO_PCM), startMs:integer≥0, endMs:integer≥startMs, byteLength:integer>0, encoding:string(jpeg/pcm_s16le_16000_mono)
S→C MEDIA_ACK	packetId:UUID, accepted:boolean, reasonCode:string/null
S→C COACHING	feedbackId:UUID, startMs:integer≥0, endMs:integer>startMs, category:string(EXPRESSION/VOICE/GAZE/POSTURE/EMOTION/SCRIPT_DELIVERY/SITUATION_FIT), message:string(1~120 자), displayDurationMs:integer(2000~3000), voiceText:string/null

방향-type	payload 필드(모두 필수, null 별도 표기)
S→C MODE_CHANGED	previousMode:string, mode:string(REALTIME/NEAR_REALTIME/POST_ONLY), reason:string(LATENCY/NETWORK/CLIENT_BACKPRESSURE)
양방향 ERROR	code:string, message:string, retryable:boolean

```
{
  "type": "AUTH",
  "eventId": "e1000000-0000-4000-8000-000000000001",
  "sessionId": "b1000000-0000-4000-8000-000000000001",
  "sequence": 0,
  "occurredAt": "2026-09-23T01:00:00Z",
  "payload": {
    "ticket": "<ws-ticket>"
  }
}
```

7.4 미디어 전송 규격

- MEDIA_META 다음에 binary frame 한 개를 전송함.
- 영상: JPEG, 최대 640×360, 초당 2 장, 256KiB 이하.
- 음성: PCM s16le / mono / 16kHz, 500ms 당 16,000bytes.
- 분석 입력과 S3 원본 업로드는 별도이며, 원본은 애플리케이션 서버 API(C04~C07)로 업로드함. 모든 ms 는 녹화 시작 기준임.

7.5 종료 코드

코드	의미
1000	정상 종료
1009	크기 초과
4401	인증 실패
4403	권한 없음
4409	상태 충돌
4429	요청 제한
1011	서버 오류

7.6 애플리케이션 서버 연계

항목	내용	확정 시점
세션 설정 전달	대본·상황 설명·코칭 설정(시각·음성·분석 전용·강도)을 세션 준비(C01) 처리 시 기대 감정 프로파일 생성 요청과 함께 AI 서버에 전달	8 장(PROFILE_REQUEST)
모드 전환 통보	AI 서버가 MODE_CHANGED 를 보낼 때 애플리케이션 서버에도 통보하여 coaching_sessions.analysis_mode 에 반영	8 장(MODE_CHANGED)
티켓 검증	C03 티켓 JWT 를 AI 서버가 공개키로 검증(7.2)	확정
서버 간 호출 인증	서비스 JWT, Redis ACL 계정, 내부망 접근 제한	8.9, 1.5

항목	내용	확정 시점
접속 범위-HTTPS	외부 공개 없음(학교 내부망 한정). 카메라 권한과 NFR-SEC-07 을 위해 Nginx 에서 HTTPS-WSS 를 종료(도메인 + Let's Encrypt)	확정(1.5)

7.7 이관 시 변경 사항

- **SESSION_STATUS 삭제:** 영상-분석 상태는 애플리케이션 DB 에 있으므로 실시간 연결로 전달하지 않음. 클라이언트는 애플리케이션 API C09(세션 상태 조회)로 조회함.
- **연결 주소:** C03 의 websocketUrl 은 같은 도메인의 /ws 경로를 가리키며 Nginx 가 AI 서버로 전달함(1.5). 애플리케이션 API 명세서에서는 '실시간 코칭' 절을 삭제하고 C03 에 본 문서 참조를 명시함.

8. AI 서버 ↔ 애플리케이션 서버 인터페이스

두 서버 사이의 연동은 메시지 큐(Redis Streams)를 기본으로 하고, 즉시 응답이 필요한 누적 취약점 개선 방향 문구만 동기 HTTP 로 처리함. 분석 상태의 기준 저장소는 애플리케이션 DB 이며, AI 서버는 결과와 상태 변화를 메시지로 전달함.

8.1 구성

구분	내용
메시지 큐	Redis Streams. 애플리케이션 서버 PC(교내)에 설치하고, AI 서버는 학교 내부망으로 접속함(1.5)
형식 정본	필드 단위 정의와 JSON 예시는 서버 간 메시지 형식 확정본 v1.0(2026. 10. 02)과 첨부 JSON 11 개를 정본으로 하며, 양쪽 개발의 테스트 데이터로 사용함
스트림	va:app-to-ai(애플리케이션 → AI 명령), va:ai-to-app(AI → 애플리케이션 이벤트), va:dead(재시도 한도 초과 메시지 격리)
소비자 그룹	va:app-to-ai 는 ai-server 그룹, va:ai-to-app 은 app-server 그룹이 소비
동기 HTTP	AI 서버가 제공하는 내부 API 1 종(8.6). 애플리케이션 서버가 서비스 JWT 로 호출
원본 영상	애플리케이션 서버가 발급한 S3 임시 다운로드 URL(presigned GET)로 AI 서버가 직접 다운로드(8.7)
Redis 부가 용도	D07 개선 방향 문구의 최근 값 캐시(8.6), 메시지 중복 처리 기록(8.5)

8.2 공통 메시지 형식

스트림 항목은 body 필드 하나에 아래 JSON 을 담음. 필드는 모두 필수이며, 시각은 UTC ISO 8601, 영상 시간은 녹화 시작 기준 ms 로 애플리케이션 API 공통 규격과 같음.

필드	자료형	설명
messageId	string(UUID)	메시지 고유 식별자. 수신 측 중복 처리 기준
type	string	메시지 종류(8.3)
schemaVersion	string	메시지 형식 버전. 1.0
occurredAt	string(date-time)	발생 시각
correlationId	string(UUID)	관련 자원 식별자(analysisId, sessionId, userId 중 메시지별 기준 값)
payload	object	메시지별 내용(8.3)

```
{
  "messageId": "f1000000-0000-4000-8000-000000000001",
  "type": "ANALYSIS_REQUEST",
  "schemaVersion": "1.0",
  "occurredAt": "2026-09-29T07:00:00Z",
  "correlationId": "a1000000-0000-4000-8000-000000000001",
  "payload": {
    "analysisId": "a1000000-0000-4000-8000-000000000001",
    "attempt": 1,
    ...
  }
}
```

8.3 메시지 목록

애플리케이션 → AI (va:app-to-ai)

type	발행 시점	payload 주요 필드	AI 서버 처리
PROFILE_REQUEST	C01 세션 준비 성공 직후, U06 업로드 분석 접수 직후	source, sessionId 또는 analysisId, userId, scriptContent, situation, coaching(visualEnabled-voiceEnabled-a nalysisOnly-intensity, 실시간만)	기대 감정 프로파일 생성(5 장) 후 situation_profiles 저장, 세션 설정 보관
ANALYSIS_REQUEST	실시간: 영상 READY 전환 직후. 재분석: C11 접수 시. 업로드: U06 접수 직후	analysisId, attempt, source, sessionId(업로드는 null), userId, media(url, contentType, durationMs, urlExpiresAt), scriptContent, situation	프로파일 준비 확인 후 전체 단위 분석(2.2) 실행
ANALYSIS_CANCEL	U09 업로드 분석 취소, 분석 대기-진행 중인 세션의 C08 취소	analysisId, attempt, reason	대기 중이면 폐기, 진행 중이면 중단. 결과 메시지를 보내지 않음
DATA_DELETE	D04 기록 삭제, C08 취소, 탈퇴 후 7 일 영구 삭제	scope(SESSION/UPLOAD_ANALYSIS/U SER), sessionId-analysisId-userId 중 해당 값, reason	situation_profiles 등 해당 데이터 삭제(6.7)
SUMMARY_REQUEST	기간 통계 갱신 시(8.8)	userId, periodType(WEEKLY/MONTHLY), periodStart, periodEnd, statisticsUpdatedAt, statistics(practiceCount, analyzedSessionCount, metrics[], 반복 취약점 요약)	LLM 으로 기간 피드백 문장 생성

AI → 애플리케이션 (va:ai-to-app)

type	발행 시점	payload 주요 필드	애플리케이션 처리
MODE_CHANGED	촬영 중 실행 모드 전환 시(7 장 MODE_CHANGED 와 동시)	sessionId, previousMode, mode, reason, atMs	coaching_sessions.analysis_mode 갱신
ANALYSIS_STATUS	분석 처리 시작 시	analysisId, attempt, status(PROCESSING), startedAt	analysis_status = PROCESSING
ANALYSIS_RESULT	분석 완료 시	analysisId, attempt, status(COMPLETED/PARTIAL), schemaVersion, modelVersion, scoringVersion, durationMs, overallScore, scores[7], summary, strengths[], improvements[], nextPractice[], segments[], rawResult, generatedAt	analyses-analysis_scores-analysis_feedbacks 저장, 상태 반영. 업로드는 원본 삭제 및 결과 만료 시각 설정
ANALYSIS_FAILED	분석 실패 시	analysisId, attempt, failureCode, retryable	8.4 규칙에 따라 재요청 또는 FAILED 처리
SUMMARY_RESULT	기간 피드백 생성 완료·실패 시	userId, periodType, periodStart, statisticsUpdatedAt, status(READY/FAILED), summary	dashboard_summaries 갱신(8.8)

ANALYSIS_RESULT 상세

필드	자료형	설명
scores[]	object[7]	category, status(AVAILABLE/UNAVAILABLE/NOT_SUPPORTED), score(0~100, 소수 1 자리)/null, confidence(0~1)/null, reasonCode/null, detail(object)
segments[]	object[] (최대 300)	feedbackId(UUID, AI 생성), startMs, endMs, category, subcategory(3.3), kind, severity, message(1~500 자), suggestion(최대 500 자)/null, detail(object)
summary, strengths[], improvements[], nextPractice[]	string, string[]	C10 길이·개수 제한과 동일(2000 자, 10 개·500 자, 10 개·500 자, 5 개·500 자)
rawResult	object	모듈별 상세 결과, 감정 코드·각성도, LLM 대체 여부(llmFallback) 등. analyses.raw_result 에 저장

※ 결과 문장 생성(LLM)에 실패하면 항목별 템플릿 문장으로 summary 등을 채워 전달하고, 점수·구간 피드백은 정상 전달함. 이때 rawResult.llmFallback = true 로 기록함.

8.4 분석 상태 전이

분석 상태는 애플리케이션 DB 의 analyses.status(실시간은 coaching_sessions.analysis_status 와 동기화)를 기준으로 하며, 메시지에 따라 아래와 같이 전이함.

현재 상태	사건	다음 상태	비고
NOT_STARTED	실시간 영상 READY(조립 완료)	QUEUED	ANALYSIS_REQUEST(attempt 1) 발행
-	U06 업로드 분석 접수	QUEUED	PROFILE_REQUEST → ANALYSIS_REQUEST 순서로 발행
QUEUED	ANALYSIS_STATUS(PROCESSING) 수신	PROCESSING	
QUEUED·PROCESSING	ANALYSIS_RESULT 수신	COMPLETED 또는 PARTIAL	세션 상태 COMPLETED. 업로드는 원본 삭제·결과 24 시간 만료 설정
QUEUED·PROCESSING	ANALYSIS_FAILED(MEDIA_URL_EXPIRED) 수신	QUEUED 유지	새 URL 로 같은 attempt 재발행(최대 2 회, 재분석 횟수 미차감)
QUEUED·PROCESSING	그 밖의 ANALYSIS_FAILED 수신	FAILED	C11 재분석 가능(원본 READY·총 3 회)
FAILED	C11 재분석 접수	QUEUED	attempt + 1 로 ANALYSIS_REQUEST 발행
QUEUED·PROCESSING	U09 취소 또는 C08 취소	CANCELED	ANALYSIS_CANCEL 발행
PROCESSING	처리 제한 시간 초과(초기값 60 분)	FAILED	failureCode = AI_TIMEOUT. C11 가능

- **지난 메시지 무시:** 애플리케이션은 attempt 가 현재 값보다 작거나, 분석이 CANCELED·삭제 상태인 경우 수신한 결과·상태 메시지를 저장하지 않고 확인(ACK)만 함.
- **AI 서버 중단 시:** 메시지는 스트림에 남아 있다가 AI 서버가 복구되면 처리되므로, 대기 중인 분석은 QUEUED 로 유지됨. 사용자에게는 분석 대기 상태로 표시됨(NFR-UX-06).

8.5 신뢰성 규칙

항목	규칙	초기값
전달 보장	최소 1 회 전달. 소비자는 XREADGROUP 으로 읽고, 처리와 저장이 끝난 뒤 XACK	-
재처리	ACK 없이 일정 시간이 지난 메시지는 XAUTOCLAIM 으로 다시 가져와 처리	5 분
실패 격리	전달 횟수가 한도를 넘은 메시지는 va:dead 로 옮기고 로그를 남김. 운영자가 확인 후 재발행	5 회
중복 처리	수신 측은 처리한 messageId 를 Redis 에 기록하고 같은 messageId 는 건너뛴. 분석은 analysisId + attempt 단위로 한 번만 수행	기록 보관 7 일

항목	규칙	초기값
발행 보장	애플리케이션은 DB 커밋 후 발행하며, 발행 실패 시 재처리 가능한 상태를 DB에 남김: 기록 삭제는 <code>coaching_sessions.deletion_status(PENDING → DONE)</code> , 탈퇴는 <code>purge</code> 스케줄러 완료 조건에 발행 성공 포함, 분석 요청은 <code>QUEUED</code> 상태 점검 스케줄러가 재발행(요구사항 5.3)	점검 주기 5 분
영속성	Redis AOF 저장(<code>appendonly yes, appendfsync everysec</code>). ACK 완료 항목은 보관 기간 경과 후 <code>XTRIM</code> 으로 정리	보관 7 일
순서	같은 분석의 메시지는 한 스트림 안에서 발행 순서대로 처리. 서로 다른 분석 사이의 순서는 보장하지 않음	-

8.6 누적 취약점 개선 방향 문구 API

D07 응답의 `suggestion` 은 애플리케이션 서버가 D07 집계 시 AI 서버에 동기 요청하여 받음. AI 서버는 LLM 없이 V-A 벡터 검색(6 장, `usage = WEAKNESS_DIRECTION`)만 수행하여 빠르게 응답함.

항목	내용
호출	POST <code>http://10.1.24.173:8804/internal/v1/weakness-suggestions</code> (AI 서버 제공, 학교 내부망 직접 호출. Nginx 로 공개하지 않음)
인증	서비스 JWT(8.9)
요청	<code>userId</code> , <code>items[]</code> : <code>category</code> , <code>subItems[]</code> (<code>subcategory</code> , <code>frequency</code> , <code>improvement</code>), <code>frequency</code> , <code>improvement</code>
응답	<code>items[]</code> : <code>category</code> , <code>suggestion</code> (최대 500 자)
제한 시간	초기값 3 초
대체 규칙	시간 초과·오류 시 ① Redis 에 캐시된 해당 사용자·항목의 최근 문구, ② 없으면 애플리케이션에 저장한 항목별 기본 문구를 사용. 정상 응답은 캐시를 갱신함

8.7 원본 영상 전달

- 애플리케이션 서버는 `ANALYSIS_REQUEST` 발행 시 원본(실시간: `session_videos.object_key`, 업로드: `video_uploads.object_key`)의 S3 임시 다운로드 URL 을 발급하여 `media.url` 에 담음. AI 서버에는 S3 자격증명을 두지 않음.
- URL 유효기간은 큐 대기과 처리 시간을 포함하도록 설정함(초기값 6 시간). 만료로 다운로드에 실패하면 AI 서버는 `ANALYSIS_FAILED(MEDIA_URL_EXPIRED, retryable = true)`를 발행함(8.4).
- AI 서버는 원본을 임시 디렉터리에 내려받아 분석하고, 분석 종료 즉시 삭제함.

8.8 기간 피드백 생성 (D05-D06 summary)

1. 애플리케이션은 LIVE_CAPTURE 분석이 COMPLETED-PARTIAL 로 확정되거나 기록이 삭제되면, 해당 세션이 속한 주간·월간 기간의 dashboard_summaries 를 PENDING 으로 바꾸고 SUMMARY_REQUEST 를 발행함.
2. 기간 내 유효 분석 세션이 없으면 요청하지 않고 INSUFFICIENT_DATA 로 둬.
3. AI 서버는 전달받은 통계로 기간 피드백 문장(초기값 2,000 자 이하)을 생성하여 SUMMARY_RESULT 로 돌려줌. 결과 문장 원칙(FR-RESULT-02-03)을 동일하게 적용함.
4. 애플리케이션은 statisticsUpdatedAt 이 저장된 최신 통계 시각과 같을 때만 READY 로 저장하고, 더 오래된 통계로 만든 결과는 버림.
5. D05-D06 은 dashboard_summaries 의 summary.status 를 그대로 응답함.

※ dashboard_summaries 테이블은 애플리케이션 DB 설계서에 정의함.

8.9 서버 간 인증

경로	인증 방식
클라이언트 → AI 서버(실시간 코칭)	Nginx(HTTPS-WSS) 경유, C03 연결 티켓 JWT(7.2)
애플리케이션 → AI 서버(동기 HTTP)	서비스 JWT. 애플리케이션 서버가 개인키로 서명(iss = app-server, aud = ai-internal, 유효 60 초), AI 서버는 연결 티켓과 같은 공개키로 검증. 학교 내부망 직접 호출
두 서버 → Redis	서버별 Redis ACL 계정·비밀번호. AI 서버 계정은 va:app-to-ai 읽기·ACK 와 va:ai-to-app 쓰기만 허용. 학교 PC 방화벽에서 Redis 포트는 애플리케이션 서버 자신과 km-ai(10.1.24.173)에서만 허용, 기본 포트 미사용. 내부망 구간이므로 TLS 는 사용하지 않음(1.5)
AI 서버 → AI 서버 DB	vectoract_ai 전용 계정. 학교 PC 방화벽과 PostgreSQL 접속 설정(pg_hba)에서 km-ai 만 허용

※ AI 서버에서 애플리케이션 서버로 가는 연동은 모두 큐를 거치므로, AI 서버용 서명 키는 두지 않음.

9. 실시간 처리 구조

실시간 코칭 연결로 들어오는 영상·음성 패킷을 처리하는 AI 서버 내부 구조와, 지연 관리·모드 전환·사후 분석 처리 규칙을 정의함. 표시된 초기값은 설정값이며 9.10 의 실측 후 조정함.

9.1 처리 구조

FastAPI 게이트웨이는 연결과 세션 상태만 관리하고, 연산이 큰 모듈은 별도 워커 프로세스에서 실행함. CPU 모듈과 GPU 모듈을 분리하여 파이썬 GIL 로 인한 상호 지연을 피함.

※ 9.1-9.2 의 처리 구조는 1 차 실측(9.10.2)에서 확인한 병목(0.5 초마다 모든 세션의 F0 를 한 줄로 계산)을 개선한 구조이며, 10/7 재측정으로 확정함(1.7).

구성 요소	실행 위치	담당
게이트웨이	FastAPI(asyncio) 프로세스, 포트 8804	WebSocket 연결, 티켓 검증(7.2), 패킷 검증·MEDIA_ACK, 세션 버퍼, 모드 판단(9.5), COACHING·MODE_CHANGED 송신
세션 코디네이터	게이트웨이 내부	0.5 초 격자 조립, M4(규칙 기반 시계열)·M9·M10·M11, 코칭 판단(11 장). 세션별 상태 보관
얼굴 워커	CPU 프로세스 여러 개	M1(MediaPipe)·M2·M3(LightGBM). 프레임 단위 무상태 처리
음성 전처리 워커	CPU 프로세스	M5(Silero VAD)·M6 음량(500ms 패킷마다), M6 F0(발화 종료 시 발화 단위). 세션별 상태를 분리하여 세션 수가 늘어도 한 줄로 기다리지 않게 함
음성 모델 워커	GPU 프로세스	M7(emotion2vec+)·M8(faster-whisper). 발화 구간 단위 요청
사후 분석 워커	별도 프로세스	va:app-to-ai 의 ANALYSIS_REQUEST 소비, 파일 드라이버로 전체 단위 분석(9.8). 얼굴·음성 워커를 낮은 우선순위로 사용
LLM·임베딩	GPU(Ollama, KURE-v1, 분석 모델과 공용)	기대 감정 프로파일, 결과 문장, 기간 피드백, D07 문구 검색. 실시간 세션 중 LLM 동시 1 건

※ 게이트웨이와 워커 사이는 프로세스 간 작업 큐로 연결하며, 구체적인 구현 방식은 개발 단계에서 정함. 실시간 세션의 작업은 사후 분석 작업보다 항상 먼저 처리함.

9.2 입력 처리 흐름

- MEDIA_META 수신 후 이어지는 binary frame 을 받아 크기·encoding·시간 범위($\text{startMs} \leq \text{endMs}$, 녹화 시작 기준)를 검증함.
- 검증 결과를 MEDIA_ACK 로 즉시 응답함. 거부 시 reasonCode 를 포함함(9.3).
- 영상은 세션별 프레임 대기열에, 음성은 세션별 연속 오디오 버퍼에 넣음.
- 영상 프레임은 얼굴 워커로, 음성은 500ms 단위로 음성 전처리 워커(CPU)로 보내 VAD·음량을 계산함. F0(M6)·STT(M8)·음성 감정(M7)은 VAD 가 발화 종료를 판정한 시점에 발화 구간 단위로 계산함(F0 는 CPU, M7·M8 은 GPU).
- 워커 결과를 세션 코디네이터가 0.5 초 격자로 조립하여 M9~M11 과 코칭 판단에 전달함.
 - 각성도 반영 시점:** 실시간 음성 각성도의 음량 요소는 0.5 초마다, F0 요소는 발화 종료 후 반영함. 억양 기반 코칭(INTONATION_FLAT)은 원래 발화 단위 판단이므로 영향이 없음.

9.3 과부하 처리

항목	규칙	초기값
영상 대기열 한도	세션별 처리 대기 프레임이 한도를 넘으면 가장 오래된 프레임부터 버림. 해당 구간은 얼굴 결과 없이 음성 결과만 사용	2 프레임(1 초)
음성 보호	음성 패킷은 버리지 않음. STT와 대본 위치 추적(FR-AI-08)이 연속 음성을 전제로 하기 때문임	-
음성 적체	처리되지 않은 음성이 한도를 넘으면 모드 전환 판단(9.5)에 반영	2 초
MEDIA_ACK 거부 사유	INVALID_META(메타 오류), SIZE_EXCEEDED(크기 초과), OUT_OF_RANGE(시간 범위 오류), BACKPRESSURE_DROPPED(과부하로 폐기), SESSION_NOT_ACTIVE(촬영 중 아님)	-

9.4 지연 목표

지표	구간	목표(초기값)
L_video	프레임 수신 → 얼굴 감정(M3) 결과	500ms 이하
L_audio	음성 패킷 수신 → VAD·음량 결과	300ms 이하
L_stt	발화 종료 → 전사(M8) 결과	1.5 초 이하
L_coach	문제 감지 → COACHING 송신(침묵 구간 대기 시간 제외)	1 초 이하

※ 세션별로 최근 10 초 이동 구간의 지연을 계속 측정하여 모드 판단(9.5)과 용량 산정(9.10)에 사용함(NFR-PERF-01·02).

9.5 모드 전환 규칙

일시적인 지연에는 전환하지 않고, 기준 초과가 일정 시간 지속될 때만 전환함(FR-CAM-06). 상황이 회복되면 한 단계씩 복귀를 허용함.

전환	조건(초기값)	MODE_CHANGED reason
REALTIME → NEAR_REALTIME	L_video 또는 L_stt 가 목표의 2 배를 10 초 연속 초과, 또는 음성 적체 2 초 초과	LATENCY
REALTIME → NEAR_REALTIME	패킷 도착 간격이 3 초 이상 벌어지는 일이 30 초 안에 3 회 이상	NETWORK
REALTIME → NEAR_REALTIME	패킷의 startMs 가 도착 시각보다 5 초 이상 뒤처짐(클라이언트 송신 지연)	CLIENT_BACKPRESSURE
NEAR_REALTIME → POST_ONLY	10 초 구간 처리가 3 구간 연속으로 구간 길이보다 오래 걸림, 또는 패킷이 30 초 이상 도착하지 않음	LATENCY 또는 NETWORK
한 단계 복귀	모든 지연 지표가 목표 이하인 상태가 30 초 연속 유지	전환 당시와 같은 reason

- **전환 간격:** 모드가 바뀐 뒤 최소 30 초는 다시 바꾸지 않아 모드가 오락가락하지 않게 함.
- **지표 측정 불가:** 지연 지표를 측정할 수 없으면 안전한 쪽(한 단계 아래)으로 전환함(FR-CAM-06).
- **장치 입력 중단:** 영상·음성 패킷이 모두 끊긴 것은 모드 문제가 아니므로 전환하지 않고 ERROR(INPUT_STOPPED)를 보내 클라이언트가 장치 오류로 처리하게 함(FR-LIVE-06, FR-ERROR-03).
- **시작 모드:** AUTHENTICATED 의 analysisMode 는 기본 REALTIME 이며, 동시 세션 한도(설정값, 1 차 실효 기준 잠정 5 개, 9.10.2)를 넘으면 NEAR_REALTIME 으로 시작함.
- **통보:** 모든 전환은 클라이언트에 MODE_CHANGED(7 장)를, 애플리케이션 서버에 MODE_CHANGED 메시지(8.3)를 보냄.

9.6 준실시간 처리

- 입력은 실시간과 같은 WebSocket 패킷을 사용하며, 녹화 시작 기준 10 초 구간(0~10 초, 10~20 초 ...)으로 묶어 처리함(FR-RECORD-04).
- 구간은 오래된 것부터 순서대로 처리하고(FR-LIVE-06), 결과는 원본 시간축 기준 ms 로 기록함.
- 직전 구간의 핵심 피드백을 다음 구간 촬영 중에 COACHING 으로 보내며, 노출 시점·쿨다운은 11.8 규칙을 따름.
- 최종 결과는 촬영 종료 후 원본 재분석으로 생성하므로, 준실시간 구간 결과는 최종 결과에 사용하지 않음(2.2).

9.7 분석 전용 모드

코칭 설정이 분석 전용(analysisOnly)이면 촬영 중 스트림 분석은 그대로 수행하되 COACHING 메시지는 보내지 않음(FR-LIVE-05). 분석 결과는 지연 측정과 모드 판단에 사용하며, MODE_CHANGED 는 정상적으로 보냄.

9.8 사후 분석 처리

항목	내용
입력	ANALYSIS_REQUEST 의 임시 다운로드 URL 로 원본을 내려받아 파일 드라이버로 처리(8.7)
영상 샘플링	원본에서 초당 5 장을 추출하고, 0.5 초 격자마다 2~3 장의 결과를 평균하여 사용
음성	원본 오디오를 16kHz mono 로 변환하여 전체 구간을 재처리
우선순위	실시간 세션이 있으면 사후 분석은 남은 처리 능력으로만 진행. GPU 동시 사후 분석 작업 수 초기값 1
진행 상태	처리 시작 시 ANALYSIS_STATUS(PROCESSING) 발행. 제한 시간(8.4) 초과 시 실패 처리

9.9 연결 끊김과 재연결

- WebSocket 이 끊겨도 세션 상태(대본 위치, 감정 시계열, 쿨다운 기록 등)를 일정 시간 보관함(초기값 60 초).
- 클라이언트는 C03 으로 새 티켓을 받아 재연결하고, 미디어는 녹화 시작 기준 startMs 를 이어서 보냄. 새 연결의 sequence 는 0 부터 다시 시작함.
- 보관 시간 안에 재연결하지 않으면 세션 상태를 해제함. 녹화와 원본 업로드는 애플리케이션 서버 흐름으로 계속되므로 최종 분석에는 영향이 없음.

9.10 실측 계획과 결과

모델 크기와 동시 실시간 세션 수는 요구사항에 수치가 없으므로 실측으로 정함. 측정은 측정 도구(vectoract-bench)로 학교 AI 서버(km-ai)에서 수행하며, 결과는 설정값으로 반영함(1.7).

단계	내용
1. 후보	faster-whisper small / medium / large-v3-turbo, emotion2vec+ base / large, 연산 정밀도 float16 / int8
2. 데이터	팀 검증셋 세트 C(대본 낭독 녹음)와 세트 B(대본 연기 영상)(4.6). 1 차는 시험용 합성 음성으로 대체
3. 모델 비교	후보 조합별 L_stt, 한국어 음절 오류율(CER), GPU 메모리 사용량 측정
4. 모델 결정	L_stt 목표(1.5 초)를 만족하는 조합 중 CER 이 가장 낮은 조합을 선택
5. 동시 세션 측정	선택한 조합으로 동시 실시간 세션 1-3-5-8 개를 모의 재생하여 9.4 지연 목표 충족 여부 측정
6. 한도 설정	모든 지연 목표를 충족하는 최대 세션 수를 동시 세션 한도로 정하고, 초과 세션은 NEAR_REALTIME 으로 시작(9.5)

9.10.1 1 차 결과: 음성 모델 (2026. 09. 30)

시험용 합성 음성(TTS) 6 개 파일, 발화 94 개로 측정함. 합성 음성은 사람 녹음보다 깨끗하므로 음절 오류율은 실제보다 낮게 나왔을 수 있음. 지연은 발화 구간이 주어진 뒤의 전사 처리 시간임.

모델	정밀도	GPU 메모리	p50	p95	음절 오류율	L_stt
large-v3-turbo	float16	2,322MB	208ms	312ms	2.0%	충족
large-v3-turbo	int8_float16	1,362MB	230ms	310ms	2.1%	충족
medium	float16	2,258MB	257ms	394ms	2.2%	충족
medium	int8_float16	1,394MB	277ms	401ms	2.1%	충족
small	float16	914MB	212ms	304ms	3.1%	충족
small	int8_float16	818MB	216ms	323ms	3.2%	충족

모델	GPU 메모리	p50	p95	비고
emotion2vec+ base	736MB	14ms	75ms	정확도는 세트 A 촬영 후 비교
emotion2vec+ large	950MB	29ms	93ms	

- **음성 인식:** large-v3-turbo 선정(4 단계 규칙). 연산 정밀도는 공용 GPU 를 고려해 int8_float16 을 초기값으로 함(오류율 차이 0.1%p, 메모리 약 40% 절감). 테스터 녹음(세트 C)으로 재측정 후 확정(설정값).
- **음성 감정:** base-large 모두 자연 목표를 충족함. 초기값 base.
- **낭독 속도:** 합성 음성 중앙값 4.97 음절/초(참고값). 11.3 기본 발화 속도 보정에는 테스터 녹음을 사용함.

9.10.2 1 차 결과: 동시 세션 (2026. 09. 30)

음성만(영상 제외), 공용 GPU, 세션당 60 초 재생 조건에서 L_audio(9.4) p95 를 측정함.

동시 세션	처음 구조(F0 를 0.5 초마다 계산)	F0 제외 측정	목표
1	298ms	36ms	300ms 이하
3	434ms	135ms	300ms 이하
5	1,104ms	136ms	300ms 이하
8	-	372ms(미달)	300ms 이하

- **원인:** 0.5 초 패킷마다 모든 세션의 F0(pYIN)를 한 줄로 계산하여 세션 수에 비례해 대기가 늘어남. 같은 측정에서 전사(L_stt) p95 는 1~3 세션에서 375~498~555ms 로 목표 안이었으므로 GPU 모델은 병목이 아님.
- **개선:** F0 를 발화 단위로 계산하고 VAD·음량을 CPU 워커로 분리함(9.1~9.2). F0 제외 측정 기준 5 세션까지 목표를 충족하고 8 세션에서 미달하여 동시 세션 한도를 잠정 5 로 둠(설정값).

9.10.3 남은 측정 (10/7)

항목	내용
구조 확인	9.1~9.2 개선 구조로 동시 세션 1~3~5~6~7~8 재측정 → 처리 구조 확정, 동시 세션 한도 설정
사람 목소리	테스터 낭독 녹음(세트 C)으로 음성 인식 정밀도와 기본 발화 속도(11.3) 확정
영상 포함	얼굴 워커를 포함한 L_video 측정(세트 B 확보 시)
LLM	Gemma 4 후보(E4B·12B·26B A4B, 4 비트)의 GPU 메모리, 기대 감정 프로파일 생성 시간, JSON 성공률 측정(5.3)
동시 부하	실시간 세션 진행 중 LLM 작업 1 건을 함께 실행하여 자연 목표 영향 확인

10. 점수 산출 로직

항목별 세부 지표를 0~100 점으로 변환하고 가중치를 적용해 항목 점수를 산출함(FR-AI-07). 점수 산출은 전체 단위 분석(사후·업로드)의 결과로만 수행하며, 실시간·준실시간 분석은 코칭 판단(11 장)에만 사용함. 표시된 기준값은 모두 초기값이며 10.8 의 보정 절차로 조정함.

10.1 설계 원칙

- **항목 역할 분리:** 표정·감정·상황 적합성이 같은 특징을 중복 반영하지 않도록 항목마다 평가 질문을 하나로 한정함(10.2).
- **상황 의존 판단은 situationFit에만:** 표준 말투를 두지 않는다는 정의(FR-AI-03)에 따라, 발화 속도·음량의 빠르기·크기가 상황에 맞는지는 situationFit에서만 평가하고, voice 는 상황과 무관한 전달력(안정성·적정 음량·단조로움)만 평가함.
- **설명 가능성:** 모든 세부 지표는 '목표 범위에서 얼마나 벗어났는가'로 점수화하여 결과 문장과 구간 피드백에서 근거를 제시할 수 있게 함.
- **가중치:** 항목 안의 세부 지표는 균등 가중치로 시작함. 종합 점수는 항목 점수의 단순 평균임(10.6).

10.2 항목 역할

항목	평가 질문	평가하지 않는 것
expression	표정이 잘 보이고 살아 있는가	어떤 감정인지(emotion), 상황에 맞는 강도인지(situationFit)
gaze	시선을 안정적으로 유지하는가	-
voice	목소리가 잘 전달되는가(안정성·적정 음량·역량 변화)	빠르기·크기가 상황에 맞는지(situationFit)
emotion	대사별로 어떤 감정을 표현했는가	감정의 강도(situationFit)
scriptDelivery	대본을 정확히 전달했는가	대본에 없는 의성어·감탄사(9 장 M9)
situationFit	상황에 맞는 강도와 톤인가	감정의 종류(emotion)
posture	1 차 범위 미지원(NOT_SUPPORTED)	-

10.3 공통 변환 함수

세부 지표 x 를 목표 범위 $[lo, hi]$ 와 허용 폭 w 로 0~100 점에 대응시킴. 범위 안이면 100 점, 범위를 벗어난 거리 d 가 w 에 이르면 0 점이며 그 사이는 선형으로 감점함.

$$\begin{aligned}
 d &= \begin{cases} 0 & (lo \leq x \leq hi) \\ lo - x & (x < lo) \\ x - hi & (x > hi) \end{cases} \\
 score &= 100 \times \max(0, 1 - d / w)
 \end{aligned}$$

항목 점수는 세부 점수의 가중 평균이며, 소수 첫째 자리까지 반올림함(C10). 계산할 수 없는 세부 지표는 제외하고 나머지로 평균함.

10.4 항목별 세부 지표 (초기값)

항목	세부 코드	지표	lo ~ hi	w
expression	FACIAL_EXPRESSION	E1 얼굴 가시 비율: 얼굴 검출 구간 / 전체 구간	0.95 ~ 1.0	0.45
		E2 표정 활성도: 눈 깜빡임을 제외한 블렌드셰이프 활성 강도의 구간 평균(0~1 정규화)	0.20 ~ 0.70	0.20
		E3 무표정 정지 비율: 5 초 이상 표정 변화가 없는 구간 / 얼굴 검출 구간	0 ~ 0.20	0.50
gaze	GAZE_HOLD	G1 시선 유지 비율: 카메라 방향 시선 구간 / 얼굴 검출 구간	0.80 ~ 1.0	0.50
		G2 시선 이탈 빈도: 1 초 이상 이탈 횟수 / 분	0 ~ 3	7
voice	SPEECH_RATE	V1 발화 속도 안정성: 발화별 음절/초의 변동계수	0 ~ 0.25	0.35
	VOLUME	V2 평균 음량: 발화 구간 RMS 평균(dBFS)	-30 ~ -10	15
	VOLUME	V3 클리핑 비율: -1 dBFS 이상 프레임 / 발화 프레임	0 ~ 0.01	0.05
	INTONATION	V4 억양 변화폭: 발화별 F0 범위(5~95 백분위, 반음) 평균	3 ~ 12	3
emotion	EMOTION_EXPRESSION	M1 대사별 감정 일치도: 대사 구간의 융합 감정 확률 중 기대 감정 확률 평균(대사 길이 가중)	0.50 ~ 1.0	0.50
	EMOTION_TRANSITION	M2 감정 전환 성공률: 기대 감정이 바뀌는 대사 경계 ±3 초 안에서 관측 전환이 일어나고 전환 후 감정이 기대와 일치한 비율	0.80 ~ 1.0	0.80
scriptDelivery	SCRIPT_ACCURACY	S1 음절 일치율: 1 - 음절 오류율(의성어·감탄사 제외)	0.95 ~ 1.0	0.45
		S2 대사 누락 비율: 일치율 30% 미만 대사 / 전체 대사	0 ~ 0	0.50
situationFit	SITUATION_FIT	F1 각성도 적합: 대사별 관측 각성도 - 기대 각성도 평균	0 ~ 0.15	0.45
		F2 운율 적합: 대사별 발화 속도·음량 변화와 기대 각성도 변화의 상관계수	0.30 ~ 1.0	0.80

- **voice 가중치:** SPEECH_RATE·VOLUME·INTONATION 세 세부 코드를 균등(1/3)하게 합치고, VOLUME 은 V2·V3 의 평균으로 계산함.
- **emotion 의 전환 지표:** 기대 프로파일에 감정 전환이 없으면 M2 는 제외하고 M1 만으로 계산함.

- **situationFit 의 운율 지표:** 대사가 3 개 미만이면 상관계수를 신뢰할 수 없으므로 F2 는 제외하고 F1 만으로 계산함.
- **시선 기준:** 1 차 범위에서는 카메라 방향을 기준으로 함. 연기상 의도적인 시선 처리는 구분하지 못하는 한계가 있음.
- **대본 누락:** 대본 일부만 연습한 경우에도 누락으로 집계되는 한계가 있음.

10.5 신뢰도(confidence)

confidence = 데이터 충분도 × 판정 확신도. 신호처리로 측정하는 항목은 확신도를 1 로 둬. 소수 셋째 자리까지 반올림함(DB NUMERIC(4,3)).

항목	데이터 충분도	판정 확신도
expression	얼굴 검출 구간 비율	1
gaze	홍채 검출 가능 구간 비율	1
voice	min(1, 발화 시간 / 30 초)	1
emotion	얼굴 또는 음성 감정이 있는 구간 비율	융합 감정 최대 확률의 평균을 $(p - 1/7) / (1 - 1/7)$ 로 정규화
scriptDelivery	min(1, 발화 시간 / 30 초)	STT 단어 확률의 평균
situationFit	기대 프로파일과 대사 구간이 대응된 대사 비율	emotion 과 같은 확신도

- **표현 제한:** confidence 가 0.4 미만인 항목은 결과 문장에서 확정적 표현을 쓰지 않음(FR-RESULT-03).
예: '빨라졌습니다' 대신 '빨라진 것으로 보입니다'.

10.6 분석 불가 판정과 종합 점수

reasonCode	조건(초기값)	UNAVAILABLE 처리 항목
FACE_NOT_DETECTED	얼굴 검출 구간 30% 미만	expression, gaze (emotion 은 음성 감정만으로 계산)
NO_SPEECH	발화 시간 5 초 미만	voice, scriptDelivery (emotion 은 얼굴 감정만으로 계산)
PROFILE_UNAVAILABLE	기대 감정 프로파일 생성 실패	situationFit, emotion
INSUFFICIENT_DATA	그 밖에 세부 지표를 하나도 계산할 수 없음	해당 항목
NOT_SUPPORTED_IN_V1	1 차 범위 미지원	posture(status = NOT_SUPPORTED)

- **UNAVAILABLE 항목:** score 와 confidence 는 null 임(C10).
- **종합 점수(overallScore):** posture 를 제외하고 status 가 AVAILABLE 인 항목 점수의 단순 평균. AVAILABLE 항목이 없으면 null(C10). 대시보드 평균(D05·D06)과 같은 방식임.

- **분석 상태:** 6 개 항목이 모두 AVAILABLE 이면 COMPLETED, 일부만 AVAILABLE 이면 PARTIAL 로 보고함(8.3).

10.7 구간 피드백 생성 기준

segments[]와 누적 취약점(D07)의 기초가 되는 구간 피드백은 세부 지표를 10 초 이동 구간으로 다시 계산하여 생성함. 세부 코드(3.3)를 함께 부여함.

종류	조건(초기값)	kind / severity
개선	구간 세부 점수 60 미만이 5 초 이상 지속	IMPROVEMENT / INFO
개선(주의)	구간 세부 점수 40 미만이 5 초 이상 지속	IMPROVEMENT / WARNING
강점	구간 세부 점수 90 이상이 10 초 이상 지속	STRENGTH / INFO

- 같은 세부 코드의 인접 구간은 하나로 합치며, 전체 구간 피드백은 C10 한도(300 개) 안에서 severity 와 지속 시간이 큰 순으로 남김.
- confidence 가 0.4 미만인 항목의 구간 피드백은 WARNING 으로 올리지 않음.

10.8 기준값 보정과 버전 관리

1. 팀 검증셋 세트 B(4.6)의 영상마다 평가자(팀원 2 명)가 항목별로 ' 좋음·보통·부족 ' 3 단계를 매김.
 2. 초기값으로 산출한 점수의 순서가 팀 평가 순서와 맞는지 확인하고, 어긋나는 세부 지표의 lo·hi·w 와 가중치를 조정함.
 3. 조정 결과를 본 장의 표에 반영하고 scoringVersion 을 올림.
- **scoringVersion:** 'MAJOR.MINOR.PATCH' 형식으로 초기값은 1.0.0 임. 기준값·가중치 조정은 MINOR, 지표 추가·삭제나 계산식 변경은 MAJOR 를 올림. 버전이 다른 기간은 대시보드에서 비교하지 않음(D05·D06 VERSION_MISMATCH).

11. 실시간 코칭 트리거 로직

촬영 중 분석 결과에서 코칭이 필요한 문제를 감지하고, 코칭 강도·쿨다운·발화 상태에 따라 COACHING 메시지(7.3)를 보낼지와 언제 보낼지를 정하는 규칙임(FR-LIVE-01~05, FR-COACH-03). 점수(10 장)는 실시간으로 계산하지 않으며, 코칭 판단은 같은 신호를 사용하되 본 장의 별도 기준을 적용함. 표시된 수치는 모두 초기값이며 11.9 의 절차로 조정함.

11.1 설계 원칙

- **필요할 때만:** 정상 연기 중에는 코칭을 보내지 않음(FR-LIVE-01, NFR-UX-05). 문제가 일정 시간 지속될 때만 코칭 후보로 등록함.

- **대사 흐름 우선:** 일반 코칭은 대사가 끝난 침묵 구간에 보내고, 발화 중에는 즉시 코칭만 보냄(FR-LIVE-03, NFR-PERF-02).
- **극적 침묵 보호:** 감정이 고조된 침묵에서는 즉시 코칭을 제외한 모든 코칭을 보내지 않음(FR-LIVE-03).
- **한 번에 하나:** 코칭은 한 번에 1 건만 보내며, 여러 문제가 겹치면 우선순위(11.5)로 고름.
- **짧고 명확하게:** 문구는 팀 작성 문구(coaching_phrases)에서 고르며 120 자 이하로 함(NFR-UX-04, 6.5).

11.2 판단 흐름

세션 코디네이터(9.1)가 0.5 초 격자마다 아래 순서로 판단함.

1. **감지:** 11.3 의 감지 조건을 확인하여, 조건을 만족한 문제를 코칭 후보로 등록함. 후보에는 issue_code, 문제 구간(startMs-endMs), 등급(즉시/WARNING/INFO), 등록 시각을 기록함.
 2. **강도 필터:** 세션의 코칭 강도(11.4)에서 발동 대상이 아닌 등급의 후보는 버림.
 3. **쿨다운·간격 확인:** 같은 issue_code 의 쿨다운과 코칭 사이 최소 간격(11.4)이 지나지 않았으면 후보를 대기시킴.
 4. **노출 시점 확인:** 일반 후보는 침묵 구간이 오고 극적 침묵이 아닐 때까지 대기함(11.5-11.6). 즉시 후보는 바로 진행함.
 5. **조건 재확인:** 보내기 직전에 문제가 아직 지속 중인지 다시 확인하고, 해소되었으면 후보를 버림.
 6. **문구 선택:** 세션 시작 시 캐시한 문구에서 issue_code 에 맞는 문구를 고름(11.7).
 7. **송신·기록:** COACHING 을 보내고 issue_code 별 마지막 송신 시각과 사용 문구를 세션 상태에 기록함. 세션 상태는 재연결 보관 시간(9.9) 동안 유지함.
- **대기 한도:** 일반 후보는 등록 후 8 초 안에 보내지 못하면 버림(오래된 코칭은 현재 연기와 맞지 않기 때문임).
 - **시작 유예:** 촬영 시작 후 5 초 동안은 연기 준비 시간으로 보고 코칭을 보내지 않음.

11.3 문제 유형(issue_code)과 감지 조건

issue_code 는 coaching_phrases.issue_code(DB 설계서 11 장)에 저장되는 값이며, 본 표가 정의 목록임. 감지 조건은 NORMAL 강도 기준 초기값임.

등급	issue_code	category · 세부 코드	감지 조건(초기값)	기본 문구(일반 강도)
즉시	FACE_OUT	EXPRESSION · FACIAL_EXPRESSION	얼굴 미검출(M1)이 2 초 연속	얼굴이 화면 밖으로 나갔어요. 화면 안으로 들어와 주세요.
즉시	VOLUME_TOO_LOW	VOICE · VOLUME	발화 중(M5) 음량이 -45 dBFS 미만인 상태가 3 초 누적	목소리가 조금 작아요. 상대 배우에게 전달한다는 느낌으로 한 단계 더 크게 말해보세요.

등급	issue_code	category · 세부 코드	감지 조건(초기값)	기본 문구(일반 강도)
즉시	MIC_DISCONNECTED	VOICE · VOLUME	영상 패킷은 도착하는데 음성 패킷이 5 초 이상 없거나, 음성이 -80 dBFS 미만(완전 무음)으로 5 초 연속	목소리가 들어오지 않아요. 마이크 연결을 확인해 주세요.
일반	SPEECH_TOO_FAST	VOICE · SPEECH_RATE	최근 10 초 발화 속도가 목표 속도보다 30% 이상 빠름	말이 조금 빨라요. 중요한 단어 사이에 짧은 호흡을 넣어보세요.
일반	SPEECH_TOO_SLOW	VOICE · SPEECH_RATE	최근 10 초 발화 속도가 목표 속도보다 30% 이상 느림	대사의 흐름이 조금 느려요. 상대방의 반응을 기다린다는 느낌으로 자연스럽게 이어가 보세요.
일반	VOLUME_CLIPPING	VOICE · VOLUME	최근 10 초 발화 프레임 중 클리핑(-1 dBFS 이상) 비율 5% 초과	소리가 갈라져서 들려요. 마이크와 거리를 조금 두고 말해보세요.
일반	INTONATION_FLAT	VOICE · INTONATION	연속 3 개 발화의 F0 변화폭(M6)이 모두 2 반음 미만	억양의 변화가 적어요. 핵심 단어에 조금 더 높낮이를 줘보세요.
일반	GAZE_AWAY	GAZE · GAZE_HOLD	얼굴이 검출된 상태에서 카메라 방향 시선 이탈 3 초 연속	시선이 오래 벗어났어요. 상대 배우가 있는 카메라 쪽으로 시선을 돌려보세요.
일반	EXPRESSION_FLAT	EXPRESSION · FACIAL_EXPRESSION	발화 중 표정 활성화도(10.4 E2)가 0.20 미만인 상태 8 초 연속. 기대 감정이 NEUTRAL 인 대사는 제외	표정 변화가 적어요. 대사의 감정에 맞춰 눈썹과 입 주변의 움직임을 조금 더 활용해보세요.
일반	EMOTION_MISMATCH	EMOTION · EMOTION_EXPRESSION	관측 우세 감정(M10)이 현재 대사의 기대 감정과 다른 상태 5 초 연속	표정과 대사의 감정이 조금 달라요. 대사의 감정을 얼굴 표정에도 연결해보세요.
일반	AROUSAL_LOW	SITUATION_FIT · SITUATION_FIT	관측 각성도가 현재 대사의 기대 각성도보다 0.3 이상 낮은 상태 5 초 연속	감정이 조금 약하게 느껴져요. 대사의 상황과 상대방을 더 의식하면서 감정을 실어보세요.
일반	AROUSAL_HIGH	SITUATION_FIT · SITUATION_FIT	관측 각성도가 현재 대사의 기대 각성도보다 0.3 이상 높은 상태 5 초 연속	감정 표현이 조금 강해요. 감정을 한 단계 낮추고 상황에 맞게 절제해보세요.
재촉	LONG_PAUSE	SCRIPT_DELIVERY · SCRIPT_ACCURACY	남은 대사가 있는 상태에서 발화 없는 침묵 6 초. 극적 침묵이면 발동하지 않음	숨이 조금 길어요. 감정의 흐름이 끊기지 않도록 조금 더 자연스럽게 이어보세요.

※ 기본 문구는 코칭 문구 최종본(별도 파일: 실시간 60 개·결과 54 개, 음성 문구 포함)의 일반 강도 문구이며, 강도별·감정별 문구와 음성 문구는 최종본을 따름(11.7).

- **목표 발화 속도:** 기본 속도 $\times (0.85 + 0.3 \times \text{현재 대사의 기대 각성도})$. 기본 속도 초기값은 5.5 음절/초이며, 팀원 낭독 녹음(9.10 2 단계)으로 보정함. 발화 속도는 STT(M8) 음절 수 / VAD 발화 시간으로 계산함.
- **현재 대사:** 대본 위치 추적(M9)이 가리키는 대사임. 위치를 잃은 상태(FR-AI-08)에서는 대사 기준 조건(EMOTION_MISMATCH, AROUSAL_LOW·HIGH, EXPRESSION_FLAT 의 제외 조건, LONG_PAUSE)을 판단하지 않음.
- **프로파일이 없을 때:** 기대 감정 프로파일이 없으면(PROFILE_UNAVAILABLE) EMOTION_MISMATCH 와 AROUSAL_LOW·HIGH 는 사용하지 않고, 목표 발화 속도의 기대 각성도는 0.5 로 둬.
- **장치 입력 중단과의 구분:** 영상·음성이 모두 끊기면 코칭이 아니라 ERROR(INPUT_STOPPED)로 처리함(9.5). MIC_DISCONNECTED 는 음성만 끊긴 경우임.
- **등급(WARNING/INFO):** 일반·재촉 후보는 감지 조건의 지속 시간(연속 발화 수 기준은 개수)의 2 배 이상 지속되면 WARNING, 그 전에는 INFO 로 등록함. 예: LONG_PAUSE 는 6 초에 INFO, 12 초에 WARNING.
- **posture:** 1 차 범위 미지원이므로 POSTURE category 의 코칭은 보내지 않음.

11.4 코칭 강도

코칭 강도(FR-COACH-03)는 발동 대상 등급, 감지 기준, 코칭 빈도를 함께 바꿈. 미선택 시 NORMAL 을 적용함.

강도	발동 대상	감지 지속 시간	같은 코칭 클다운	코칭 사이 최소 간격
MINIMAL(최소)	즉시 + WARNING	11.3 기준	30 초	20 초
NORMAL(일반)	즉시 + WARNING + INFO	11.3 기준	20 초	10 초
INTENSIVE(집중)	즉시 + WARNING + INFO	11.3 기준 $\times 0.7$ (0.5 초 단위 올림)	15 초	6 초

- **클다운:** 같은 issue_code 를 다시 보내기까지의 최소 시간으로, 세 강도 모두 요구사항 범위(15~30 초, FR-LIVE-02) 안에서 정함.
- **최소 간격:** 종류와 관계없이 마지막 COACHING 송신 후 다음 일반 코칭까지의 최소 시간임. 즉시 코칭은 최소 간격을 적용받지 않으나, 즉시 코칭 뒤의 일반 코칭에는 적용함.

- **즉시 코칭의 별도 기준:** 즉시 코칭은 강도와 관계없이 같은 감지 조건으로 발동하고 쿨다운을 적용하지 않음(FR-LIVE-02 비교). 다만 조건이 계속되는 동안에는 10 초 간격으로만 다시 보내며 최대 3 회까지 보냄. 조건이 해소된 뒤 다시 발생하면 처음부터 적용함.

11.5 노출 시점과 우선순위

항목	규칙(초기값)
침묵 구간	VAD(M5) 비발화 상태가 0.6 초 이상 지속된 시점부터 침묵 구간으로 봄
일반·재촉 코칭	침묵 구간이면서 극적 침묵(11.6)이 아닐 때 보냄. 조건을 만족할 때까지 최대 8 초 대기 후 버림(11.2)
즉시 코칭	발화 중에도 바로 보냄(FR-LIVE-03 비교)
표시 중 중복 방지	직전 COACHING 의 표시 시간(displayDurationMs)이 끝나기 전에는 다음 COACHING 을 보내지 않음. 즉시 코칭도 표시 종료를 기다림(최대 3 초)
우선순위	즉시 > WARNING > INFO 순으로 고르고, 같은 등급이면 먼저 등록된 후보를 고름. 고르지 못한 후보는 대기 한도 안에서 다음 기회를 기다림
표시 시간	$displayDurationMs = 2000 + 50 \times \max(0, \text{문구 글자 수} - 10)$, 상한 3000(7.3 범위). 즉시 코칭은 3000
L_coach	후보 등록부터 송신까지의 처리 시간 목표 1 초에서 침묵 대기·표시 대기 시간은 제외함(9.4)

11.6 극적 침묵 판단

침묵 구간이 시작될 때 아래 두 조건 중 하나라도 만족하면 극적 침묵으로 판단하고, 해당 침묵이 끝날 때까지 유지함.

구분	조건(초기값)	근거
관측 기준	침묵 직전 3 초의 평균 각성도(M10)가 0.7 이상이고, 같은 구간의 우세 감정이 ANGER-SADNESS-FEAR-SURPRISE 중 하나	실제로 감정이 고조된 상태(극대노, 오열 직전 등)
대본 기준	직전 대사 또는 다음 대사의 기대 각성도(5 장 프로파일)가 0.7 이상(클라이맥스 대사)	관측이 약하더라도 대본상 의도된 멈춤일 수 있음

- **억제 범위:** 극적 침묵 중에는 즉시 코칭을 제외한 모든 코칭(재촉 코칭 포함)을 보내지 않음. 대기 중인 후보는 다음 일반 침묵까지 대기 한도 안에서 기다림.
- **LONG_PAUSE:** 극적 침묵이 6 초를 넘어도 재촉 코칭은 발동하지 않음. 극적 침묵이 아닌 침묵에서만 LONG_PAUSE 를 감지함.
- **프로파일이 없을 때:** 대본 기준은 적용하지 않고 관측 기준만 사용함.

11.7 문구 선택

- 세션 시작 시 캐시:** AUTHENTICATED 전에 coaching_phrases 에서 usage = REALTIME_COACHING, 활성 문구, intensity 가 세션 강도이거나 NULL 인 문구를 issue_code 별로 조회하여 메모리에 보관함(6.3). 대본의 기대 감정이 있으면 감정·각성도 맥락으로 벡터 검색(6.4)하여 issue_code 별 상위 문구를 함께 캐시함.
- 감정 우선:** EMOTION_MISMATCH·AROUSAL_LOW·AROUSAL_HIGH 는 현재 대사의 기대 감정과 emotion_code 가 같은 문구를 우선 사용함(예: 기대 감정 SADNESS → '슬픔이 잘 보이지 않아요. 울지 않으려고 참는 마음으로, 말끝을 조금 낮춰보세요.').
- 반복 회피:** 같은 issue_code 의 문구가 여러 개면 세션 안에서 직전에 사용한 문구를 제외하고 순환함.
- 문구가 없을 때:** 캐시에 해당 issue_code 문구가 없으면 11.3 의 기본 문구를 사용함.
 - 문구 출처:** coaching_phrases 에는 코칭 문구 최종본(10/2 확정 문구 16 개 반영)을 적재함. 판단 기준이 없는 2 종(시선 고정, 호흡 불안정)은 보류함(12.2).
 - category:** COACHING.category 는 11.3 의 category 값을 그대로 사용함.
 - 음성 코칭:** 음성 코칭이 ON 이면 voiceText 에 문구의 voice_text(없으면 content)를 넣고, OFF 이면 null 로 보냄(FR-LIVE-04). 즉시 코칭이 발화 중에 발생한 경우에는 사용자 대사와 겹치지 않도록 voiceText 를 null 로 보냄.

11.8 모드와 코칭 설정별 동작

상황	동작
REALTIME	11.2~11.7 규칙을 그대로 적용
NEAR_REALTIME	10 초 구간(9.6) 처리가 끝나면 그 구간에서 감지된 후보 중 우선순위가 가장 높은 1 건을 다음 구간 촬영 중에 보냄. 쿨다운·최소 간격·노출 시점·극적 침묵 규칙은 같게 적용하고, 대기 한도는 다음 구간이 끝날 때까지로 함. 즉시 코칭은 구간 끝까지 조건이 지속된 경우에만 보냄
POST_ONLY	촬영 중 분석을 하지 않으므로 코칭을 보내지 않음
분석 전용(analysisOnly)	감지는 수행하되 COACHING 을 보내지 않음(9.7, FR-LIVE-05)
시각 OFF · 음성 ON	COACHING 을 보내며 클라이언트는 voiceText 만 재생함. 발화 중 즉시 코칭은 voiceText 가 null 이 되므로 침묵 구간까지 대기 한도 안에서 기다린 뒤 보냄
시각 OFF · 음성 OFF	제공할 코칭 수단이 없으므로 분석 전용과 같게 처리
모드 전환 시	대기 중인 후보는 버리고, 쿨다운·마지막 송신 기록은 유지함

11.9 초기값 보정

1. 팀 검증셋 세트 B(4.6)를 실시간 세션처럼 재생하여 강도별로 발송·억제된 코칭 내역을 기록함. 내역은 보정용 운영 로그로만 남기고 DB 에는 저장하지 않음.
 2. 10.8 에서 '좋은'으로 평가된 영상에서 NORMAL 기준 일반 코칭이 분당 1 회를 넘지 않는지 확인함(FR-LIVE-01 정상 연기 시 미표시).
 3. '부족'으로 평가된 항목의 주요 문제 구간에서 해당 issue_code 가 발동하는지 확인함.
 4. 팀원이 코칭 시점이 연기를 방해했다고 표시한 사례를 모아 침묵 판정 시간, 극적 침묵 기준, 대기 한도를 조정함.
- 감지 조건·강도별 수치를 바꾸면 본 장의 표에 반영하고 문서 이력에 기록함. 코칭 기준은 저장되는 점수에 영향을 주지 않으므로 scoringVersion(10.8)은 올리지 않음.

12. 설정값 목록과 남은 확인 사항

12.1 설정값으로 관리하는 항목

아래 항목은 구조가 아닌 설정값이므로 측정·보정 결과에 따라 문서 개정 없이 조정함(1.7).

No.	항목	현재 초기값	조정 근거
1	음성 인식 모델·정밀도	large-v3-turbo, int8_float16, beam 1	10/7 재측정(세트 C)
2	음성 감정 모델 크기	emotion2vec+ base	세트 A 정확도 비교
3	LLM 크기	Gemma 4 후보 E4B-12B-26B A4B(4 비트) 중 측정 후 지정	10/7 측정(5.3)
4	동시 실시간 세션 한도	5(잠정)	10/7 재측정(9.10.3)
5	발화 감지(VAD)	threshold 0.18, 최소 발화 300ms, 최소 무음 200ms, padding 350ms	후속 확인(12.2)
6	영역 2·5 시간 초기값	지연 목표, 모드 전환 조건, 대기열 한도, 재처리 5 분, 처리 제한 60 분, URL 6 시간, D07 3 초, 재연결 보관 60 초, LLM 동시 1 건	운영 측정
7	점수 기준값·가중치	10 장 초기값(lo·hi·w), 시선·대본 복구·융합 임계값	세트 B(10.8)
8	코칭 트리거 초기값	11 장 감지 조건, 강도별 쿨다운·간격, 침묵·극적 침묵 기준, 기본 발화 속도 5.5 음절/초	세트 B·C(11.9)
9	코칭 문구	코칭 문구 최종본 114 개	세트 B 테스트 후 수정
10	DB 백업 보관 기간	7 일	운영
11	감정 시계열 GRU	1 차 규칙 기반	학습 데이터 확보 후

12.2 기준선 확정 전 남은 확인 사항

No.	항목	내용	시점
1	실시간 처리 구조	9.1-9.2 개선 구조를 재측정으로 확인한 뒤 확정(2026. 10. 03 결정: 재측정 후 확정)	10/7
2	학교 DNS 확인	도메인 등록 후 학교 DNS 가 내부 IP 응답을 돌려주는지 확인. 막히면 사설 DNS-hosts 로 전환(1.5)	도메인 구매 후
3	VAD 튜닝 근거	F1 정답 기준-비교 단위-기본값 대비 결과, 발화 길이 분포(1 초 미만 비율), padding 을 시간 계산에도 적용하는지, 발화 종료 판정 기준, 실시간 스트림 적용 시 동작	VAD 담당
4	보류 코칭 문구	시선 고정(설계의 시선 유지 기준과 방향이 반대), 호흡 불안정(판단할 신호 없음)	판단 기준 확정 시
5	학교 PC 정보	애플리케이션 서버 PC 내부 IP 기재, 443 포트-외부 연결-km-ai 8804 접속 확인	PC 설치 시

12.3 애플리케이션 문서 수정 현황

AI 서버 설계 과정에서 결정된 사항 중 애플리케이션 문서에 반영할 내용과 반영 상태임.

문서	수정 내용	상태
API 명세서	S03-S04(AI 대본 생성) 삭제	반영 완료
API 명세서	S01-S02 응답의 situation 필드 삭제, jobId 설명을 'OCR 작업 식별자'로 수정	반영 완료
API 명세서	C03 websocketUrl 을 AI 서버 주소로 명시하고 본 문서 참조 추가	반영 완료
API 명세서	C03 ticket 을 애플리케이션 서버가 서명한 JWT(aud=ai-server)로 명시	반영 완료
API 명세서	'실시간 코칭' 절 삭제(본 문서 7 장으로 이관), C09 에 촬영 중 상태 조회 안내 추가	반영 완료
API 명세서	D07 items[].subItems[] 세부 항목 집계 추가, C10-U08 modelVersion 형식 명시	반영 완료
DB 설계서	script_jobs 의 AI_GENERATION-request_data 설명-result_situation 정리, 관련 표현 수정	반영 완료
DB 설계서	analysis_feedbacks.subcategory 컬럼-CHECK-인덱스 추가, 집계 기준-API 매핑 갱신	반영 완료
요구사항분석서	FR-UPLOAD-02 업로드 분석 항목에 '시선' 추가	반영 완료
요구사항분석서	FR-RESULT-03 개선점 분류 기준을 7 개 category 체계로 표기 정리	반영 완료
요구사항분석서	FR-AI-03 말투 정의(자연어-의성어를 포함한 발화 전반, 표준 말투 없음) 명시	반영 완료

문서	수정 내용	상태
요구사항분석서	FR-LIVE-06-FR-RESULT-01 '전 구간 결과 통합'을 '전체 원본 영상 기반 최종 분석'으로 수정	반영 완료
UI/UX 명세서	9.5.3.2 업로드 분석 항목에 '시선' 추가	반영 완료
UI/UX 명세서	8.2 예시 문구 '당황스러운 표정'을 7 종 감정 체계 표현으로 수정	반영 완료
DB 설계서	11 장 AI 서버 DB 신설: pgvector 확장, coaching_phrases 테이블·인덱스 추가	반영 완료
UI/UX 명세서	10.5 취약점 분석 항목에 상황 적합성 추가	반영 완료
API 명세서	D07 improvement-improvementStatus 필드 추가(최근 30 일 대 직전 30 일)	반영 완료
DB 설계서	7 장 집계 기준에 누적 취약점 개선 정도 산출 규칙 추가	반영 완료
DB 설계서	dashboard_summaries(기간 피드백) 테이블 신설, 연결 티켓·Redis 사용 범위, 삭제 통보 재처리 기준, 집계·매핑 갱신	반영 완료
API 명세서	D05-D06 summary 생성 주체(AI 서버, 비동기), D07 suggestion 출처와 대체 규칙 명시	반영 완료
API 명세서·DB 설계서	영역 2 결정(준실시간 입력은 실시간 코칭 연결 패킷 사용)으로 추가 변경 없음을 확인하여 최종본 확정	반영 완료
API 명세서·DB 설계서	영역 4 결정으로 추가 변경 없음 확인: issue_code 는 coaching_phrases 의 기존 컬럼 값으로 사용(목록은 본 문서 11.3), COACHING 메시지 형식과 코칭 강도 값(MINIMAL/NORMAL/INTENSIVE)은 그대로 사용	반영 완료
DB 설계서	1 장 AI 서버 DB 설명과 11 장 제목·첫 문단: '별도 PostgreSQL 인스턴스' → '애플리케이션 서버 PC 의 PostgreSQL 안 별도 데이터베이스(vectoract_ai), 계정 분리'. 테이블 구조 변경 없음	반영 완료
DB 설계서	범위 문단: '같은 EC2 인스턴스의 Redis' → '애플리케이션 서버(교내 PC)의 Redis'	반영 완료
API 명세서	C03 webSocketUrl 설명: 'AI 서버 주소' → '같은 도메인의 /ws 경로(Nginx 가 AI 서버로 전달)'. 필드 형식 변경 없음	반영 완료
요구사항분석서·UI/UX 명세서	10/2~10/3 결정으로 변경 사항 없음(LLM 로컬 실행 유지, 음성 코칭 기본값 OFF 유지)	확인 완료

13. 부록: 설계 결정 이력

구분	결정 사항	선택	결정일
P1	최종 결과 생성 방식	혼합: 음성 원본 재처리 + 영상 샘플링 재분석, 실시간 결과는 코칭 전용	2026. 09. 29

구분	결정 사항	선택	결정일
P2	한국어 음성 인식	faster-whisper	2026. 09. 29
P3	음향 특징·VAD	Librosa + Silero VAD	2026. 09. 29
P4	대본-발화 비교	음절 단위 편집거리 정렬	2026. 09. 29
P5	감정 추정	MediaPipe + LightGBM(얼굴), 감정 시계열, emotion2vec+(음성)	2026. 09. 29
P6	상황 적합성·문장 생성	LLM(기대 감정 프로파일, 결과 문장)	2026. 09. 29
V	벡터 DB 활용	V-A 코칭·연습 문구 검색만 채택	2026. 09. 29
E1	감정 라벨 체계	국제 표준 7 종	2026. 09. 29
E2	각성도 지표	추가	2026. 09. 29
E3	얼굴 학습 데이터	공개 데이터 + AI Hub 일부, 팀 촬영 검증셋 병행	2026. 09. 29
E4	AI Hub '불안'	FEAR 근사 매핑	2026. 09. 29
E5	감정 시계열 역할	감정 안정화 + 전환 감지 + 각성도	2026. 09. 29
E6	감정 시계열 구현	1 차 규칙 기반, 데이터 확보 후 GRU 교체	2026. 09. 29
E7	얼굴·음성 융합 위치	마지막 단계 신뢰도 가중 평균	2026. 09. 29
E8	공통 시간축	0.5 초 격자	2026. 09. 29
S	AI 대본 생성(S03-S04)	이번 범위에서 제외	2026. 09. 29
P1'	최종 결과 방식 재확인	혼합 방식 유지(POST_ONLY 모드 유지), 공통 분석 엔진 구조 채택	2026. 09. 29
L	LLM	Gemma 4 31B, Ollama 로컬 서빙(→ L2 로 변경)	2026. 09. 29
EMB	텍스트 임베딩	KURE-v1(1024 차원), 로컬 실행	2026. 09. 29
HW	서버 하드웨어	RTX A6000 48GB × 2, 분석 모델(GPU 0)과 LLM·임베딩(GPU 1) 분리(→ HW2 로 변경)	2026. 09. 29
SYS	서버·DB 구성	애플리케이션 서버와 AI 서버 분리, AI 서버 전용 PostgreSQL 인스턴스(→ INF7 로 변경)	2026. 09. 29
WS	실시간 코칭 연결	클라이언트 ↔ AI 서버 직접 연결, 프로토콜은 AI 서버 설계서로 이관(→ INF3 에 따라 Nginx /ws 경유)	2026. 09. 29
WS2	SESSION_STATUS 메시지	삭제, 세션 상태는 C09 로 조회	2026. 09. 29
SUB	취약점 세부 항목	7 개 category 유지 + 세부 항목 코드 도입(A 안)	2026. 09. 29
UPG	업로드 분석 시선	포함(요구사항·UI 문구 수정)	2026. 09. 29
OCR	S01-S02 situation 필드	삭제	2026. 09. 29
OCR2	대본 이미지 OCR 기능	유지(S01-S02 는 애플리케이션 서버에서 계속 제공, S03-S04 만 삭제)	2026. 09. 29
TKT	연결 티켓 검증	C03 티켓을 서명 JWT 로 발급, AI 서버가 공개키로 검증	2026. 09. 29

구분	결정 사항	선택	결정일
MT	말투 정의	자연어·의성어를 포함한 발화 전반, 표준 말투 없음	2026. 09. 29
PO	POST_ONLY 모드	유지(전환 조건은 9.5)	2026. 09. 29
FRL	FR-LIVE-06 문구	전체 원본 영상 기반 최종 분석	2026. 09. 29
LIC	모델·데이터 이용 조건	출업작품 범위에서 모두 사용 가능(상용화 시 재검토)	2026. 09. 29
EXT	외부 AI API 전환 조건	LLM·임베딩을 외부 API 로 전환 시 개인정보처리방침 반영	2026. 09. 29
DOC	coaching_phrases 문서 위치	DB 설계서 11 장(AI 서버 DB)에 정본 수록	2026. 09. 29
UIW	취약점 화면 상황 적합성	UI 10.5 에 표시	2026. 09. 29
IMP	D07 개선 정도	필드 추가, 직전 30 일 반복 빈도 – 최근 30 일 반복 빈도(각 기간 3 세션 미만이면 비교 불가)	2026. 09. 29
NET	AI 서버 운영 환경	대학교 AI 서버, 포트 개방으로 테스트 통신(→ INF1~INF5 로 구체화)	2026. 09. 29
ONO	의성어·감탄사 처리	대본 비교(M9)에서 오류로 집계하지 않고, 음성 감정·각성도 분석(M6-M7)에는 포함. 말투는 표준 비교 없이 상황 적합성(M11)으로 평가	2026. 09. 29
IF1	서버 간 통신	메시지 큐(Redis Streams), 애플리케이션 서버와 같은 EC2 인스턴스에 설치(→ INF1 에 따라 교내 PC 에 설치)	2026. 09. 29
IF2	원본 영상 전달	S3 임시 다운로드 URL(presigned GET)	2026. 09. 29
IF3	통보 재전송	큐의 재처리 기능 + 애플리케이션 기존 상태 컬럼으로 발행 보장	2026. 09. 29
IF4	서버 간 인증	서비스 JWT(애플리케이션 서명), Redis ACL·TLS·IP 제한(→ INF4 로 변경)	2026. 09. 29
IF5	D07 개선 방향 문구	D07 집계 시 AI 서버 동기 호출, 실패 시 최근 문구 → 기본 문구	2026. 09. 29
IF6	주간·월간 기간 피드백	AI 서버가 LLM 으로 비동기 생성, 애플리케이션 DB dashboard_summaries 에 저장	2026. 09. 29
RT1	준실시간 입력 소스	실시간 코칭 연결 패킷(애플리케이션 변경 없음)	2026. 09. 29
RT2	준실시간 구간 길이	10 초	2026. 09. 29
RT3	모드 전환	지속 조건 기반 하향 전환, 회복 시 한 단계씩 복귀 허용	2026. 09. 29
RT4	분석 전용 모드	촬영 중 분석 수행, 코칭만 미송신(FR-LIVE-05 유지)	2026. 09. 29
RT5	처리 구조	게이트웨이 + CPU 얼굴 워커 + GPU 음성 워커 분리	2026. 09. 29
RT6	과부하 처리	영상은 오래된 프레임부터 폐기, 음성은 폐기하지 않음	2026. 09. 29
RT7	사후 분석 샘플링	원본에서 초당 5 장	2026. 09. 29
RT8	모델 크기·동시 세션 한도	실측 절차(9.10)로 결정	2026. 09. 29

구분	결정 사항	선택	결정일
SC1	항목 역할	항목별 평가 질문 분리(emotion = 감정 종류, situationFit = 강도·톤, voice = 상황 무관 전달력)	2026. 09. 29
SC2	점수 변환	목표 범위형 선형 감점, 상황 의존 판단은 situationFit 에서만	2026. 09. 29
SC3	기준값	공학적 초기값으로 시작, 팀 검증셋으로 보정	2026. 09. 29
SC4	신뢰도	데이터 충분도 × 판정 확신도(모델 사용 항목만)	2026. 09. 29
SC5	항목 내 가중치	균등 가중치로 시작	2026. 09. 29
SC6	종합 점수	AVAILABLE 항목 점수의 단순 평균(API 변경 없음)	2026. 09. 29
CT1	일반 코칭 노출 시점	침묵 구간까지 최대 8 초 대기, 넘으면 버림	2026. 09. 29
CT2	코칭 강도 적용 범위	발동 대상 등급·감지 기준·빈도를 함께 조정(MINIMAL 30 초/20 초, NORMAL 20 초/10 초, INTENSIVE 15 초/6 초)	2026. 09. 29
CT3	극적 침묵 판단	관측 각성도 기준 또는 기대 프로파일의 클라이맥스 대사 기준 중 하나라도 만족	2026. 09. 29
CT4	극적 침묵 중 억제 범위	즉시 코칭을 제외한 모든 코칭 억제	2026. 09. 29
CT5	문제 유형 코드	즉시 3 종·일반 9 종·재촉 1 종(11.3), 등급은 지속 시간 2 배 기준으로 WARNING/INFO 구분	2026. 09. 29
CT6	즉시 코칭 반복	쿨다운 미적용, 조건 지속 중 10 초 간격 최대 3 회	2026. 09. 29
PRF	기대 감정 프로파일 저장·삭제	AI 서버 DB 에 저장, 애플리케이션 서버의 삭제 통보(기록 삭제·취소·탈퇴)와 만료 시각(30 일·24 시간)으로 삭제(6.7)	2026. 09. 29
STT	음성 인식 모델	faster-whisper large-v3-turbo(정밀도는 설정값)	2026. 09. 30
VAD	발화 감지 초기값	threshold 0.18, 최소 발화 300ms, 최소 무음 200ms, padding 350ms(Micro F1 0.826)	2026. 10. 01
PY	Python 버전	3.12(3.12.3 이상)	2026. 10. 01
INF1	애플리케이션 서버 위치	교내 PC(AWS EC2 안 폐기, 지도교수 결정)	2026. 10. 02
INF2	외부 공개	하지 않음. 학교 내부망 한정(포트포워딩·Cloudflare Tunnel 미사용)	2026. 10. 02
INF5	AI 서버 포트	8804(포트 끝자리 = 조 번호 규칙)	2026. 10. 02
INF6	원본 영상 저장소	AWS S3 유지(임시 URL 방식, API·DB 변경 없음)	2026. 10. 02
INF7	AI 서버 DB 위치	애플리케이션 서버 PC 의 PostgreSQL 안 별도 데이터베이스(vectoract_ai), 계정 분리	2026. 10. 02
HW2	서버 하드웨어	Quadro RTX 6000 24GB × 1(공용), 분석 모델·LLM·임베딩 같은 GPU	2026. 10. 02
MSG	서버 간 메시지 형식	확정본 v1.0(4 장 a~h 제안값 확정, i 는 내부망 직접 접속으로 변경)	2026. 10. 02

구분	결정 사항	선택	결정일
CP	코칭 문구	최종본 114 개(실시간 60·결과 54, 음성 문구 포함), 10/2 확정 문구 16 개 반영(2 중 보류)	2026. 10. 02
L2	LLM	Gemma 4 소형 모델 로컬 실행(후보 E4B-12B-26B A4B, 크기는 측정 후 설정값), 외부 API 미사용	2026. 10. 03
INF3	HTTPS	Nginx 에서 종료, 도메인 + Let's Encrypt(DNS 인증), 공개 DNS 에 내부 IP 등록(막히면 사설 DNS-hosts)	2026. 10. 03
INF4	서버 간 구간 보안	내부망 일반 연결 + 방화벽 접근 제한·계정 인증(TLS 미사용)	2026. 10. 03
RT9	실시간 처리 구조 개선	F0 발화 단위 계산, VAD·음량 CPU 워커 분리(10/7 재측정 후 확정)	2026. 10. 03
MOD	AI 모델 표기	분석 모델 5 종 + 전처리 모델 1 종(Silero VAD)	2026. 10. 03
INF8	DB 백업	매일 pg_dump, 학교 PC 에 보관(초기값 7 일)	2026. 10. 03
INF9	서비스 실행	애플리케이션 서버 PC:km-ai 모두 systemd 등록(km-ai 는 지도교수 sudo 부여)	2026. 10. 03
BL	기준선 규칙	구조·인터페이스는 팀장 승인·이력·버전, 설정값은 문서 개정 없이 조정(1.7)	2026. 10. 03